Uvod u umjetnu inteligenciju – pismeni ispit (2021./2022.)

– NEKORIGIRANA VERZIJA –

*Ispit se sastoji od **20 pitanja** i ukupno nosi **20 bodova**. Točan odgovor nosi 1 bod a netočan -1/3 boda. Trajanje ispita je **150 minuta**. Primjerak ispita trebate predati zajedno sa svojim rješenjima.*

1. Pretraživanje prostora stanja i igranje igara (4 pitanja)

1 (P) Poželjno svojstvo aloritma pretraživanja jest da je optimalan. Međutim, algoritmi "najbolji prvi" i "uspon na vrh" nisu optimalni. Oba su ova algoritma "pohlepna", ali je algoritam "najbolji prvi" manje pohlepan od algoritma "uspon na vrh", pa u praksi postoji veća vjerojatnost da će algoritam "najboji prvi" pronaći optimalan put. Skicirajte prostor stanja $S = \{a, b, c, d, e, f\}$ s prijelazima $succ(a) = \{b, c\}$, $succ(b) = \{d, e\}$, $succ(c) = succ(d) = succ(e) = \{f\}$. Cijene svih prijelaza su jednake i iznose 1. Heuristika neka je $h(b) = 1$, $h(d) = h(e) = 3$ i $h(f) = 0$. Stanje a je početno stanje, a stanje f je ciljno stanje. **Za koju vrijednost heuristike za stanje c** algoritam "uspona na vrh" *ne* pronalazi optimalno rješenje, ali ga algoritam "najbolji prvi" pronalazi?

A $h(c) = 2$ B $h(c) = 4$ C $h(c) = 5$ D $h(c) = 0$

2 (R) Razmatramo igru za dva igrača sa sumom nula. Svako stanje $s \in S$ te igre može se sažeto opisati troznamenkastim prirodnim brojem između 111 i 999. Sljedbenička stanja od s jesu sva ona stanja koja se dobivaju iz s tako da se jedna znamenka poveća za jedan, npr., $succ(235) = \{335, 245, 236\}$. Međutim, stanja koja sadrže znamenku 9 su završna stanja i ona nemaju sljedbeničkih stanja, npr., $succ(932) = \emptyset$. U završnim stanjima, isplata za prvog igrača (MAX) jednaka je razlici prve i treće znamenke, npr., $utility(932) = 9 - 2 = 7$. Isplata za drugog igrača (MIN) je negativna vrijednost isplate za prvog igrača. U igri se natječu dva algoritma minimax, A_1 (igrač MAX) i A_2 (igrač MIN). Oba algoritma pretražuju do dva poteza unaprijed, tj. dubinsko ograničenje algoritma minimax jednako je 2. Međutim, algoritmi koriste različite heuristike. Heuristika h_1 algoritma A_1 jednaka je prvoj znamenci iz s, a heuristika h_2 algorithma A_2 (definirana iz perspektive tog algoritma) jednaka je trećoj znamenci iz s. Npr., $h_1(236) = 2$ i $h_2(236) = 6$ (kod izračuna minimax vrijednosti u stablu sa MAX korijenom vrijednost heuristike h_2 trebate negirati). Početno stanje igre neka je $s_0 = 175$. Prvi potez vuče algoritam A_1 (igrač MAX). **Koji je slijed stanja igre, ako oba igrača vuku svoje minimax-optimalne poteze?**

A $175 \to 176 \to 276$ B $175 \to 275 \to 375$ C $175 \to 176 \to 186$ D $175 \to 275 \to 276$

3 (T) Složenost problema pretraživanja prostora stanja opisali smo parametrima $|S|$, b, d i m. O tim parametrima ovisi kako će se neki algoritam pretraživanja ponašati na dotičnom problemu. Neka je k konačan prirodan broj. **U kojem slučaju će nepotpun algoritam sigurno terminirati (završiti s izvođenjem)?**

A $m = d + k$ B $d = |S| + k$ C $b < k \cdot |S|$ D $b \leq m \cdot k$

4 (R) Neka su definirani skup stanja $S = \{a, b, c, d, e, f\}$ i funkcija sljedbenika $succ(a) = \{(b, 1), (c, 2)\}$, $succ(b) = succ(f) = \emptyset$, $succ(c) = \{(d, 3), (e, 5)\}$, $succ(d) = \{(b, 8), (f, 5)\}$, te $succ(e) = \{(d, 1), (f, 2)\}$. Heurističke vrijednosti čvorova neka su $h(a) = 7$, $h(b) = 4$, $h(c) = 6$, $h(d) = h(e) = 2$, $h(f) = 0$. Početno stanje neka je a, a ciljno f. Izvršite pretraživanje algoritmom A^*, bilježeći pritom sadržaje liste otvorenih čvorova O i zatvorenih čvorova C u svakom koraku algoritma (u nultom koraku $O = [(a, 0)]$ i $C = \emptyset$). **Koji su sadržaji listi O i C nakon petog koraka izvođenja algoritma A^*?**

A Algoritam ne dostiže peti korak

B $O = [(f, 10)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5), (e, 7)\}$

C $O = [(f, 9)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5), (e, 7)\}$

D $O = [(e, 7), (f, 10)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5)\}$

2. Prikazivanje znanja i automatsko zaključivanje (4 pitanja)

5 (P) Neka $F \equiv P \wedge \Big((P \rightarrow S) \wedge (S \rightarrow U)\Big)$ i $G \equiv F \wedge \neg S$. **Što od sljedećeg vrijedi za formule F i G?**

- A F je zadovoljiva (konzistentna), a G nije
- B Obje formule su zadovoljive (konzistentne)
- C Obje formule su kontradikcije
- D Obje formule su tautologije

6 (T) Postupak rezolucije u logici prvog reda (FOL) oslanja se na algoritam najopćenitijeg zajedničkog unifikatora (MGU). **Što je rezultat algoritma MGU, u slučaju kada se dva izraza mogu unificirati?**

- A Skup parova izraza i varijabli FOL
- B Neprazan skup atoma i varijabli FOL
- C Rezolventa ili prazna (nil) klauzula
- D Formula FOL u obliku disjunkcije konjunkcija

7 (T) Kod prikazivanja znanja formalnom logikom postoji kompromis između ekspresivnosti i odlučivosti sustava logike. **Što to točno znači?**

- A U logičkom sustavu s potpunim skupom pravila zaključivanja neke logičke posljedice ne možemo dokazati
- B Logički sustav koji može vrlo detaljno opisati stvarni svijet ne može izvesti mnoge logičke posljedice
- C Uključivanjem varijabli logički sustav može opisati relacije između objekata, ali postaje nepotpun
- D Što je u logičkom sustavu veći skup epistemičkih pretpostavki, to je manji skup ontoloških pretpostavki

8 (R) Želimo dokazati sljedeću relaciju deduktivne posljedice:

$$\forall x\Big(P(x,a) \rightarrow \neg\forall y\big(Q(y) \rightarrow \exists z R(z,y)\big)\Big),\ \exists x\forall y\Big(Q(y) \rightarrow R(x,y)\Big)\ \vdash\ \exists x\neg\Big(P(c,x) \wedge R(x,c)\Big).$$

Pretvorite premise i negaciju ciljne formule u klauzalni oblik te primijenite rezoluciju opovrgavanjem uz strategiju skupa potpore (SoS). **Koliko klauzula ulazi u postupak te je li cilj dokaziv i u koliko rezolucijskih koraka?**

- A 5 klauzula; dokazivo u 4 koraka
- B 4 klauzule; dokazivo u 4 koraka
- C 3 klauzule; dokazivo u 2 koraka
- D 4 klauzule; nije dokazivo

3. Logičko programiranje i ekspertni sustavi (2 pitanja)

9 (R) Baza znanja ekspertnog sustava sadrži sljedeća pravila:

(1) AKO $(A = a_2) \wedge (D = d_2)$ ONDA $C = c_1$
(2) AKO $(F = f_3) \vee (B = b_3)$ ONDA $C = c_2$
(3) AKO $(E = e_1) \vee (B = b_1)$ ONDA $(A = a_1) \wedge (D = d_2)$
(4) AKO $F = f_1$ ONDA $D = d_2$
(5) AKO $F = f_2$ ONDA $E = e_2$
(6) AKO $(B = b_3) \vee (D = d_1)$ ONDA $(E = e_1) \wedge (A = a_2)$

Sustav koristimo za izvođenje vrijednosti varijable C ulančavanjem unazad. Prednost imaju pravila s manjim rednim brojem. Pravila koja su jednom palila više ne mogu paliti. Jednom izvedeni međuciljevi brišu se sa stoga, neovisno o njihovoj poziciji na stogu. Na možebitne upite od strane sustava, korisnik odgovara sa $B = b_3$ i $F = f_1$. **Što radi ekspertni sustav pri izvođenju vrijednosti varijable C?**

- A Završava s četiri činjenice u radnoj memoriji
- B Pali šest pravila i izvodi $C = C_2$
- C Završava s tri činjenice u radnoj memoriji
- D Izvodi $A = a_2$ te kasnije $A = a_1$

10 (T) Semantika operatora negacije u Prologu (operator `not`) temelji se na pretpostavci zatvorenog svijeta. **Što ta pretpostavka znači?**

- A Sve dedukcije su logičke posljedice
- B Sve što ne slijedi iz baze znanja je lažno
- C U bazu se ne mogu dodavati nova pravila
- D Svaka istinita činjenica može se dokazati

4. Modeliranje neizvjesnosti (2 pitanja)

11 (T) Bayesovo pravilo čini temelj vjerojatnosnog modeliranja neizvjesnog znanja. **Koju vjerojatnost modelira Bayesovo pravilo, i kako?**

- A Vjerojatnost hipoteze prije predočavanja dokaza na temelju (1) vjerojatnosti hipoteze uz predočen dokaz i (2) združene vjerojatnosti dokaza i hipoteze
- B Uvjetnu vjerojatnost hipoteze uz predočen dokaz na temelju (1) uvjetne vjerojatnost dokaza uz predočenu hipotezu i (2) vjerojatnosti hipoteze prije predočavanja dokaza
- C Združenu vjerojatnost hipoteze i dokaza na temelju (1) uvjetne vjerojatnosti dokaza u predočenu hipotezu i (2) vjerojatnosti dokaza neovisno o hipotezi
- D Uvjetnu vjerojatnost dokaza uz predočenu hipotezu na temelju (1) vjerojatnosti hipoteze prije predočavanja dokaza i (2) vjerojatnosti dokaza neovisno o hipotezi

12 (P) Razmotrimo jezičnu varijablu *starost kanarinca*, definiranu s izrazima *mlad* i *star*. Značenje tih izraza modeliramo neirazitim skupovima M odnosno S, definiranima nad univerzalnim skupom $\mathbb{R}^+$, koji odgovara godinama. Funkcije pripadnosti μ_M i μ_S definiramo kao po dijelovima linearne funkcije. Funkcija $\mu_M(x)$ ima vrijednost 1 za $0 \leq x \leq 5$, vrijednost 0 za $x \geq 9$, te linearno pada za $5 < x < 9$. Funkcija $\mu_S(x)$ ima vrijednost 0 za $0 \leq x \leq 6$, vrijednost 1 za $x \geq 12$, te linearno raste za $6 < x < 12$. Uporabom Zadehovih operatora definiramo dva neizrazita skupa: skup X_1 sa značenjem *mlad ili star kanarinac* te skup X_2 sa značenjem *mlad ili ne mlad kanarinac*. **Za koje se sve elemente $x \in \mathbb{R}^+$ pripadnost ovim dvama neizrazitim skupovima razlikuje?**

A $9 \leq x \leq 12$ B $7 \leq x \leq 9$ C $7 \leq x \leq 12$ D $5 \leq x \leq 6$

5. Strojno učenje, umjetne neuronske mreže i podržano učenje (5 pitanja)

13 (T) Algoritam propagacije pogreške unazad (engl. *backpropagation algorithm*) rješava problem dodjele odgovornosti pojedinih neurona mreže. Preciznije, algoritam definira kako izračunati pogrešku $\delta_i^{(k)}$ neurona i u sloju k, gdje je k bilo koji skriveni sloj mreže. **O čemu ovisi pogreška $\delta_i^{(k)}$?**

- A O pogreškama svih neurona u sloju k čiji su izlazi izravno ili neizravno povezani s neuronima izlaznog sloja
- B O razlici ostvarnog i ciljanog izlaza, $t_j - o_j$, za sve neurone j u skrivenom sloju $k-1$ (sloj bliže ulazu)
- C O pogreškama svih neurona u sloju $k+1$ (sloj bliže izlazu) čiji su ulazi povezani s izlazom neurona i
- D O izlazima svih neurona u slojevima $k-1$ (sloj bliže ulazu) čiji su izlazi povezani s ulazom neurona i

14 (P) Radimo svoju implementaciju algoritma ID3. Kako bismo spriječili da se model prenauči, implementirali smo i podrezivanje stabla na dubini k. Nažalost, kod implementacije funkcije informacijske dobiti (IG) potkrala nam se mala pogreška: zaboravili smo negirati vrijednost pri izračunu entropije $E(D)$ skupa primjera D. Dakle, umjesto da izračunava $E(D)$, naša implementacija izračunava $-E(D)$. Neka je M_1^k stablo odluke koje dobivamo učenjem takvim pogrešno implementiranim algoritmom ID3, podrezano na neku konačnu dubinu k. Neka je M_2^k stablo koje bismo dobili da smo algoritam ID3 implementirali ispravno i naučeno stablo podrezali na neku konačnu dubinu k. Ako $k = \infty$, onda to znači da stablo ne podrezujemo. Neka je $E_u(M)$ pogreška učenja modela M, a $E_p(M)$ pogreška modela M na skupu za provjeru. **Što od sljedećeg možemo očekivati da vrijedi?**

A $E_p(M_2^k) < E_u(M_2^k)$ B $E_p(M_1^\infty) > E_p(M_2^\infty)$ C $E_p(M_1^\infty) < E_u(M_1^\infty)$ D $E_p(M_1^\infty) = E_p(M_2^\infty)$

15 (R) Skup primjera za učenje $\{(x_2, x_1, y)\}$ je $\{(1,1,-1),(2,4,1),(1,2,-1),(3,3,1),(2,1,-1),(4,2,1)\}$. Učenje se provodi uporabom perceptrona TLU s izlaznim vrijednostima -1 i 1 te stopom učenja $\eta = 1$. Početne vrijednosti težinskih faktora su $(w_2, w_1, w_0) = (1.3, 1.2, -3.2)$. Provedite postupak učenja Rosenblattovim algoritmom. **Koliko se puta tijekom učenja provode korekcije težina te koje su njihove konačne vrijednosti?**

A 3 puta, $(-5.2, 0.7, 1.2)$ B 2 puta, $(-1.1, 0.8, -6.9)$ C 4 puta, $(5.5, -1.5, 10)$ D 3 puta, $(1.3, 1.2, -5.2)$

16 (R) Treniramo naivan Bayesov klasifikator za *"Skupo ljetovanje na Jadranu"*. Skup za učenje je sljedeći:

i	Mjesto	Otok	Smještaj	Prijevoz	y	i	Mjesto	Otok	Smještaj	Prijevoz	y
1	Kvarner	da	privatni	auto	1	5	Kvarner	ne	kamp	bus	0
2	Dalmacija	da	hotel	avion	1	6	Dalmacija	ne	privatni	avion	0
3	Istra	da	kamp	auto	0	7	Istra	ne	kamp	bus	1
4	Dalmacija	da	hotel	auto	1						

Procjene radimo Laplaceovim procjeniteljem "dodaj jedan". Klasificiramo primjer $\mathbf{x} = (\text{Dalmacija}, \text{ne}, \text{kamp}, \text{bus})$. **Koliko iznosi aposteriorna vjerojatnost $P(y = 1|\mathbf{x})$?**

A 0.318 B 0.706 C 0.685 D 0.237

17 (P) Rešetkasti svijet sastoji se od četiri ćelije, označene brojevima 1 do 4 i poredane vodoravno slijeva nadesno. Ćelija 4 je terminalna i agentu donosi 1 bod; nema drugih bodova. Svijet je okružen zidovima. Agent može poduzeti akcije *lijevo* i *desno*. Ako bi ga akcija dovela na zid, ostaje u ćeliji u kojoj je bio. Agent uvijek kreće iz ćelije 1. Provodimo postupak Q-učenja. Početni iznosi Q-funkcije su 0. Parametri su $\alpha = 0.5$ i $\gamma = 1$. Agent najprije igra tri epizode u kojima uvijek bira akciju *desno* i uči. Nakon toga igra još 10 epizoda u kojima u svakoj ćeliji pohlepno odabire potez koji mu se čini optimalan i također uči. **Nakon provedenih svih 13 epizoda, koja je očekivana vrijednost $q(3, desno)$?**

A Nije moguće odgovoriti B Manja od 0.75 C Veća od 0.9995 D Između 0.75 i 0.9995

6. Prirodom inspirirani optimizacijski algoritmi (3 pitanja)

18 (P) Ako kod algoritma Ant System postavimo parametre $\alpha = 0$ i $\beta = 1$, **što će biti posljedica?**

A Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo količini feromonskih tragova

B U algoritmu se neće događati isparavanje feromonskih tragova

C Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo heurističkoj informaciji

D Vjerojatnost odabira nekog brida neće ovisiti o feromonskim tragovima

19 (T) Genetički algoritmi oponašaju proces biološke evolucije te implementiraju operatore selekcije, križanja i mutacije. Neka je P populacija kromosoma te neka je $\mathcal{P}$ skup svih populacija. Neka operatori selekcije, križanja i mutacije odgovaraju funkcijama s, k, odnosno m. **Kako možemo formalno opisati preslikavanja koja obavljaju te funkcije?**

A $s : \mathcal{P} \to P$, $k : P \times P \to P$, $m : P \to P \times P$

B $s : \mathcal{P} \to P \times P$, $k : P \times P \to P \times P$, $m : P \to P$

C $s : P \to \mathcal{P}$, $k : P \times P \to P$, $m : P \times P \to \mathcal{P}$

D $s : \mathcal{P} \to P \times P \times P$, $k : P \times P \to \mathcal{P}$, $m : P \times P \to P$

20 (R) Generacijskim genetskim algoritmom tražimo maksimum funkcije $f(x, y) = 20 - (x - 3)^2 - (y - 4)^2$. Kao reprezentaciju rješenja koristimo 6-bitovni kromosom, pri čemu se prva tri bita koriste za kodiranje vrijednosti varijable x, a preostala tri bita za kodiranje vrijednosti varijable y. Domena nad kojom se pretražuju vrijednosti od x je $[1, 8]$ te od y je $[0, 7]$. Populacija se sastoji od četiri jedinke: J1=000110, J2=011001, J3=100111, J4=001110. Pretpostavite da se roditelji biraju proporcionalnom selekcijom te da su u jednom koraku kao roditelji izvučena dva rješenja koja imaju najmanju vjerojatnost odabira. Provedite nad njima postupak križanja s jednom točkom prijeloma (točka prijeloma je nakon prva dva bita); pretpostavite da u ovom koraku operator mutacije svaki puta djeluje na posljednja dva bita kromosoma. **Odredite iznos funkcije f u rješenju koje odgovara djetetu koje će biti poslano u sljedeću generaciju.** (Ako ih operatori križanja i mutacije generiraju više, u novu generaciju treba proslijediti najbolje.)

A 7 B 18 C 11 D 20

Uvod u umjetnu inteligenciju – pismeni ispit (2021./2022.)

– NEKORIGIRANA VERZIJA –

*Ispit se sastoji od **20 pitanja** i ukupno nosi **20 bodova**. Točan odgovor nosi 1 bod a netočan -1/3 boda. Trajanje ispita je **150 minuta**. Primjerak ispita trebate predati zajedno sa svojim rješenjima.*

1. Pretraživanje prostora stanja i igranje igara (4 pitanja)

1 (R) Razmatramo igru za dva igrača sa sumom nula. Svako stanje $s \in S$ te igre može se sažeto opisati troznamenkastim prirodnim brojem između 111 i 999. Sljedbenička stanja od s jesu sva ona stanja koja se dobivaju iz s tako da se jedna znamenka poveća za jedan, npr., $succ(235) = \{335, 245, 236\}$. Međutim, stanja koja sadrže znamenku 9 su završna stanja i ona nemaju sljedbeničkih stanja, npr., $succ(932) = \emptyset$. U završnim stanjima, isplata za prvog igrača (MAX) jednaka je razlici prve i treće znamenke, npr., $utility(932) = 9 - 2 = 7$. Isplata za drugog igrača (MIN) je negativna vrijednost isplate za prvog igrača. U igri se natječu dva algoritma minimax, A_1 (igrač MAX) i A_2 (igrač MIN). Oba algoritma pretražuju do dva poteza unaprijed, tj. dubinsko ograničenje algoritma minimax jednako je 2. Međutim, algoritmi koriste različite heuristike. Heuristika h_1 algoritma A_1 jednaka je prvoj znamenci iz s, a heuristika h_2 algorithma A_2 (definirana iz perspektive tog algoritma) jednaka je trećoj znamenci iz s. Npr., $h_1(236) = 2$ i $h_2(236) = 6$ (kod izračuna minimax vrijednosti u stablu sa MAX korijenom vrijednost heuristike h_2 trebate negirati). Početno stanje igre neka je $s_0 = 175$. Prvi potez vuče algoritam A_1 (igrač MAX). **Koji je slijed stanja igre, ako oba igrača vuku svoje minimax-optimalne poteze?**

A $175 \rightarrow 275 \rightarrow 375$ B $175 \rightarrow 176 \rightarrow 276$ C $175 \rightarrow 275 \rightarrow 276$ D $175 \rightarrow 176 \rightarrow 186$

2 (P) Poželjno svojstvo aloritma pretraživanja jest da je optimalan. Međutim, algoritmi "najbolji prvi" i "uspon na vrh" nisu optimalni. Oba su ova algoritma "pohlepna", ali je algoritam "najbolji prvi" manje pohlepan od algoritma "uspon na vrh", pa u praksi postoji veća vjerojatnost da će algoritam "najboji prvi" pronaći optimalan put. Skicirajte prostor stanja $S = \{a, b, c, d, e, f\}$ s prijelazima $succ(a) = \{b, c\}$, $succ(b) = \{d, e\}$, $succ(c) = succ(d) = succ(e) = \{f\}$. Cijene svih prijelaza su jednake i iznose 1. Heuristika neka je $h(c) = 2$, $h(d) = h(e) = 3$ i $h(f) = 0$. Stanje a je početno stanje, a stanje f je ciljno stanje. **Za koju vrijednost heuristike za stanje** b algoritam "uspona na vrh" *ne* pronalazi optimalno rješenje, ali ga algoritam "najbolji prvi" pronalazi?

A $h(b) = 4$ B $h(b) = 1$ C $h(b) = 3$ D $h(b) = 5$

3 (R) Neka su definirani skup stanja $S = \{a, b, c, d, e, f\}$ i funkcija sljedbenika $succ(a) = \{(b, 1), (c, 2)\}$, $succ(b) = succ(f) = \emptyset$, $succ(c) = \{(d, 3), (e, 5)\}$, $succ(d) = \{(b, 8), (f, 5)\}$, te $succ(e) = \{(d, 1), (f, 2)\}$. Heurističke vrijednosti čvorova neka su $h(a) = 7$, $h(b) = 4$, $h(c) = 6$, $h(d) = h(e) = 2$, $h(f) = 0$. Početno stanje neka je a, a ciljno f. Izvršite pretraživanje algoritmom A^*, bilježeći pritom sadržaje liste otvorenih čvorova O i zatvorenih čvorova C u svakom koraku algoritma (u nultom koraku $O = [(a, 0)]$ i $C = \emptyset$). **Koji su sadržaji listi O i C nakon petog koraka izvođenja algoritma A^*?**

A Algoritam ne dostiže peti korak

B $O = [(e, 7), (f, 10)],\ C = \{(a, 0), (b, 1), (c, 2), (d, 5)\}$

C $O = [(f, 9)],\ C = \{(a, 0), (b, 1), (c, 2), (d, 5), (e, 7)\}$

D $O = [(e, 7), (f, 10), (b, 13)],\ C = \{(a, 0), (b, 1), (c, 2), (d, 5)\}$

4 (T) Složenost problema pretraživanja prostora stanja opisali smo parametrima $|S|$, b, d i m. O tim parametrima ovisi kako će se neki algoritam pretraživanja ponašati na dotičnom problemu. Neka je k konačan prirodan broj. **U kojem slučaju će nepotpun algoritam sigurno terminirati (završiti s izvođenjem)?**

A $d = |S| + k$ B $b \leq m \cdot k$ C $m = d + k$ D $b < k \cdot |S|$

2. Prikazivanje znanja i automatsko zaključivanje (4 pitanja)

5 (P) Neka $F \equiv P \wedge \big((P \rightarrow S) \wedge (S \rightarrow U)\big)$ i $G \equiv F \wedge \neg S$. **Što od sljedećeg vrijedi za formule** F **i** G**?**

A Obje formule su tautologije

B G je zadovoljiva (konzistentna), a F nije

C Obje formule su zadovoljive (konzistentne)

D F je zadovoljiva (konzistentna), a G nije

6 (T) Postupak rezolucije u logici prvog reda (FOL) oslanja se na algoritam najopćenitijeg zajedničkog unifikatora (MGU). **Što je rezultat algoritma MGU, u slučaju kada se dva izraza mogu unificirati?**

A Skup parova izraza i varijabli FOL

B Rezolventa ili prazna (nil) klauzula

C Neprazan skup atoma i varijabli FOL

D Formula FOL u obliku disjunkcije konjunkcija

7 (R) Želimo dokazati sljedeću relaciju deduktivne posljedice:

$$\forall x\Big(P(x,a) \rightarrow \neg\forall y\big(Q(y) \rightarrow \exists z R(z,y)\big)\Big),\ \forall x \exists y\Big(Q(y) \rightarrow R(y,x)\Big)\ \vdash\ \exists x \neg P(c,x).$$

Pretvorite premise i negaciju ciljne formule u klauzalni oblik te primijenite rezoluciju opovrgavanjem uz strategiju skupa potpore (SoS). **Koliko klauzula ulazi u postupak te je li cilj dokaziv i u koliko rezolucijskih koraka?**

A 5 klauzula; dokazivo u 4 koraka

B 4 klauzule; dokazivo u 4 koraka

C 4 klauzule; nije dokazivo

D 5 klauzula; dokazivo u 2 koraka

8 (T) Kod prikazivanja znanja formalnom logikom postoji kompromis između ekspresivnosti i odlučivosti sustava logike. **Što to točno znači?**

A Uključivanjem varijabli logički sustav može opisati relacije između objekata, ali postaje nepotpun

B Logički sustav koji može vrlo detaljno opisati stvarni svijet ne može izvesti mnoge logičke posljedice

C U logičkom sustavu s potpunim skupom pravila zaključivanja neke logičke posljedice ne možemo dokazati

D Što je u logičkom sustavu veći skup epistemičkih pretpostavki, to je manji skup ontoloških pretpostavki

3. Logičko programiranje i ekspertni sustavi (2 pitanja)

9 (T) Semantika operatora negacije u Prologu (operator `not`) temelji se na pretpostavci zatvorenog svijeta. **Što ta pretpostavka znači?**

A Svaka istinita činjenica može se dokazati

B Sve što ne slijedi iz baze znanja je lažno

C Sve dedukcije su logičke posljedice

D Baza znanja sadrži konačan broj činjenica

10 (R) Baza znanja ekspertnog sustava sadrži sljedeća pravila:

(1) AKO $(A = a_2) \wedge (D = d_2)$ ONDA $C = c_1$

(2) AKO $(F = f_3) \vee (B = b_3)$ ONDA $C = c_2$

(3) AKO $(E = e_1) \vee (B = b_1)$ ONDA $(A = a_1) \wedge (D = d_2)$

(4) AKO $F = f_1$ ONDA $D = d_2$

(5) AKO $F = f_2$ ONDA $E = e_2$

(6) AKO $(B = b_3) \vee (D = d_1)$ ONDA $(E = e_1) \wedge (A = a_2)$

Sustav koristimo za izvođenje vrijednosti varijable C ulančavanjem unazad. Prednost imaju pravila s manjim rednim brojem. Pravila koja su jednom palila više ne mogu paliti. Jednom izvedeni međuciljevi brišu se sa stoga, neovisno o njihovoj poziciji na stogu. Na možebitne upite od strane sustava, korisnik odgovara sa $B = b_3$ i $F = f_1$. **Što radi ekspertni sustav pri izvođenju vrijednosti varijable** C**?**

A Odbacuje pravilo 3 te kasnije pali pravilo 4

B Odbacuje pravilo 6 te kasnije pali pravilo 3

C Odbacuje pravilo 5 te kasnije pali pravilo 6

D Odbacuje pravilo 2 te kasnije pali pravilo 5

4. Modeliranje neizvjesnosti (2 pitanja)

11 (P) Razmotrimo jezičnu varijablu *starost kanarinca*, definiranu s izrazima *mlad* i *star*. Značenje tih izraza modeliramo neirazitim skupovima M odnosno S, definiranima nad univerzalnim skupom $\mathbb{R}^+$, koji odgovara godinama. Funkcije pripadnosti μ_M i μ_S definiramo kao po dijelovima linearne funkcije. Funkcija $\mu_M(x)$ ima vrijednost 1 za $0 \leq x \leq 5$, vrijednost 0 za $x \geq 9$, te linearno pada za $5 < x < 9$. Funkcija $\mu_S(x)$ ima vrijednost 0 za $0 \leq x \leq 6$, vrijednost 1 za $x \geq 12$, te linearno raste za $6 < x < 12$. Uporabom Zadehovih operatora definiramo dva neizrazita skupa: skup X_1 sa značenjem *mlad ili star kanarinac* te skup X_2 sa značenjem *mlad ili ne mlad kanarinac*. **Za koje se sve elemente $x \in \mathbb{R}^+$ pripadnost ovim dvama neizrazitim skupovima razlikuje?**

A $7 \leq x \leq 9$ B $5 \leq x \leq 6$ C $9 \leq x \leq 12$ D $7 \leq x \leq 12$

12 (T) Bayesovo pravilo čini temelj vjerojatnosnog modeliranja neizvjesnog znanja. **Koju vjerojatnost modelira Bayesovo pravilo, i kako?**

A Združenu vjerojatnost hipoteze i dokaza na temelju (1) uvjetne vjerojatnosti dokaza u predočenu hipotezu i (2) vjerojatnosti dokaza neovisno o hipotezi

B Uvjetnu vjerojatnost hipoteze uz predočen dokaz na temelju (1) uvjetne vjerojatnost dokaza uz predočenu hipotezu i (2) vjerojatnosti hipoteze prije predočavanja dokaza

C Uvjetnu vjerojatnost dokaza uz predočenu hipotezu na temelju (1) vjerojatnosti hipoteze prije predočavanja dokaza i (2) vjerojatnosti dokaza neovisno o hipotezi

D Vjerojatnost hipoteze prije predočavanja dokaza na temelju (1) vjerojatnosti hipoteze uz predočen dokaz i (2) združene vjerojatnosti dokaza i hipoteze

5. Strojno učenje, umjetne neuronske mreže i podržano učenje (5 pitanja)

13 (R) Skup primjera za učenje $\{(x_2, x_1, y)\}$ je $\big\{(1,1,-1),(2,4,1),(1,2,-1),(3,3,1),(2,1,-1),(4,2,1)\big\}$. Učenje se provodi uporabom perceptrona TLU s izlaznim vrijednostima -1 i 1 te stopom učenja $\eta = 1$. Početne vrijednosti težinskih faktora su $(w_2, w_1, w_0) = (1.3, -1.2, -10)$. Provedite postupak učenja Rosenblattovim algoritmom. **Koliko se puta tijekom učenja provode korekcije težina te koje su njihove konačne vrijednosti?**

A 2 puta, $(3.3, 2.8, -10)$ B 3 puta, $(-5.2, 0.7, 1.2)$ C 2 puta, $(-1.1, 0.8, -6.9)$ D 3 puta, $(1.3, 1.2, -5.2)$

14 (P) Radimo svoju implementaciju algoritma ID3. Kako bismo spriječili da se model prenauči, implementirali smo i podrezivanje stabla na dubini k. Nažalost, kod implementacije funkcije informacijske dobiti (IG) potkrala nam se mala pogreška: zaboravili smo negirati vrijednost pri izračunu entropije $E(D)$ skupa primjera D. Dakle, umjesto da izračunava $E(D)$, naša implementacija izračunava $-E(D)$. Neka je M_1^k stablo odluke koje dobivamo učenjem takvim pogrešno implementiranim algoritmom ID3, podrezano na neku konačnu dubinu k. Neka je M_2^k stablo koje bismo dobili da smo algoritam ID3 implementirali ispravno i naučeno stablo podrezali na neku konačnu dubinu k. Ako $k = \infty$, onda to znači da stablo ne podrezujemo. Neka je $E_u(M)$ pogreška učenja modela M, a $E_p(M)$ pogreška modela M na skupu za provjeru. **Što od sljedećeg možemo očekivati da vrijedi?**

A $E_p(M_1^\infty) = E_u(M_1^\infty)$ B $E_u(M_2^k) < E_u(M_2^\infty)$ C $E_p(M_1^\infty) > E_p(M_2^\infty)$ D $E_u(M_2^k) = E_u(M_2^\infty)$

15 (T) Algoritam propagacije pogreške unazad (engl. *backpropagation algorithm*) rješava problem dodjele odgovornosti pojedinih neurona mreže. Preciznije, algoritam definira kako izračunati pogrešku $\delta_i^{(k)}$ neurona i u sloju k, gdje je k bilo koji skriveni sloj mreže. **O čemu ovisi pogreška $\delta_i^{(k)}$?**

A O pogreškama svih neurona u sloju $k+1$ (sloj bliže izlazu) čiji su ulazi povezani s izlazom neurona i

B O izlazima svih neurona u slojevima $k-1$ (sloj bliže ulazu) čiji su izlazi povezani s ulazom neurona i

C O pogreškama svih neurona u sloju k čiji su izlazi izravno ili neizravno povezani s neuronima izlaznog sloja

D O razlici ostvarnog i ciljanog izlaza, $t_j - o_j$, za sve neurone j u skrivenom sloju $k-1$ (sloj bliže ulazu)

16 (R) Treniramo naivan Bayesov klasifikator za *"Skupo ljetovanje na Jadranu"*. Skup za učenje je sljedeći:

i	Mjesto	Otok	Smještaj	Prijevoz	y	i	Mjesto	Otok	Smještaj	Prijevoz	y
1	Kvarner	da	privatni	auto	1	5	Kvarner	ne	kamp	bus	0
2	Dalmacija	da	hotel	avion	1	6	Dalmacija	ne	privatni	avion	0
3	Istra	da	kamp	auto	0	7	Istra	ne	kamp	bus	1
4	Dalmacija	da	hotel	auto	1						

Procjene radimo Laplaceovim procjeniteljem "dodaj jedan". Klasificiramo primjer $\mathbf{x} = (\text{Dalmacija}, \text{ne}, \text{kamp}, \text{bus})$. **Koliko iznosi aposteriorna vjerojatnost** $P(y = 1|\mathbf{x})$**?**

A 0.706 B 0.685 C 0.237 D 0.318

17 (P) Rešetkasti svijet sastoji se od četiri ćelije, označene brojevima 1 do 4 i poredane vodoravno slijeva nadesno. Ćelija 4 je terminalna i agentu donosi 1 bod; nema drugih bodova. Svijet je okružen zidovima. Agent može poduzeti akcije *lijevo* i *desno*. Ako bi ga akcija dovela na zid, ostaje u ćeliji u kojoj je bio. Agent uvijek kreće iz ćelije 1. Provodimo postupak Q-učenja. Početni iznosi Q-funkcije su 0. Parametri su $\alpha = 0.5$ i $\gamma = 1$. Agent najprije igra tri epizode u kojima uvijek bira akciju *desno* i uči. Nakon toga igra još 10 epizoda u kojima u svakoj ćeliji pohlepno odabire potez koji mu se čini optimalan i također uči. **Nakon provedenih svih 13 epizoda, koja je očekivana vrijednost** $q(3, desno)$**?**

A Veća od 0.9995 B Između 0.75 i 0.9995 C Manja od 0.75 D Nije moguće odgovoriti

6. Prirodom inspirirani optimizacijski algoritmi (3 pitanja)

18 (P) Ako kod algoritma Ant System postavimo parametre $\alpha = 0$ i $\beta = 1$, **što će biti posljedica?**

A Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo količini feromonskih tragova

B U algoritmu se neće događati isparavanje feromonskih tragova

C Vjerojatnost odabira nekog brida neće ovisiti o feromonskim tragovima

D Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo heurističkoj informaciji

19 (R) Generacijskim genetskim algoritmom tražimo maksimum funkcije $f(x, y) = 13 - (x - 2)^2 - (y - 3)^2$. Kao reprezentaciju rješenja koristimo 6-bitovni kromosom, pri čemu se prva tri bita koriste za kodiranje vrijednosti varijable x, a preostala tri bita za kodiranje vrijednosti varijable y. Domena nad kojom se pretražuju vrijednosti od x je $[0, 7]$ te od y je $[-1, 6]$. Populacija se sastoji od četiri jedinke: J1=000110, J2=011001, J3=100111, J4=001110. Pretpostavite da se roditelji biraju proporcionalnom selekcijom te da su u jednom koraku kao roditelji izvučena dva rješenja koja imaju najmanju vjerojatnost odabira. Provedite nad njima postupak križanja s jednom točkom prijeloma (točka prijeloma je nakon prva dva bita); pretpostavite da u ovom koraku operator mutacije svaki puta djeluje na posljednja dva bita kromosoma. **Odredite iznos funkcije** f **u rješenju koje odgovara djetetu koje će biti poslano u sljedeću generaciju.** (Ako ih operatori križanja i mutacije generiraju više, u novu generaciju treba proslijediti najbolje.)

A 4 B 13 C 0 D 11

20 (T) Genetički algoritmi oponašaju proces biološke evolucije te implementiraju operatore selekcije, križanja i mutacije. Neka je P populacija kromosoma te neka je $\mathcal{P}$ skup svih populacija. Neka operatori selekcije, križanja i mutacije odgovaraju funkcijama s, k, odnosno m. **Kako možemo formalno opisati preslikavanja koja obavljaju te funkcije?**

A $s : \mathcal{P} \to P \times P \times P$, $k : P \times P \to \mathcal{P}$, $m : P \times P \to P$

B $s : P \to \mathcal{P}$, $k : P \times P \to P$, $m : P \times P \to \mathcal{P}$

C $s : \mathcal{P} \to P$, $k : P \times P \to P$, $m : P \to P \times P$

D $s : \mathcal{P} \to P \times P$, $k : P \times P \to P \times P$, $m : P \to P$

Uvod u umjetnu inteligenciju – pismeni ispit (2021./2022.)

– NEKORIGIRANA VERZIJA –

*Ispit se sastoji od **20 pitanja** i ukupno nosi **20 bodova**. Točan odgovor nosi 1 bod a netočan -1/3 boda. Trajanje ispita je **150 minuta**. Primjerak ispita trebate predati zajedno sa svojim rješenjima.*

1. Pretraživanje prostora stanja i igranje igara (4 pitanja)

1 (P) Poželjno svojstvo aloritma pretraživanja jest da je optimalan. Međutim, algoritmi "najbolji prvi" i "uspon na vrh" nisu optimalni. Oba su ova algoritma "pohlepna", ali je algoritam "najbolji prvi" manje pohlepan od algoritma "uspon na vrh", pa u praksi postoji veća vjerojatnost da će algoritam "najboji prvi" pronaći optimalan put. Skicirajte prostor stanja $S = \{a, b, c, d, e, f\}$ s prijelazima $succ(a) = \{b, c\}$, $succ(b) = \{d, e\}$, $succ(c) = succ(d) = succ(e) = \{f\}$. Cijene svih prijelaza su jednake i iznose 1. Heuristika neka je $h(c) = 2$, $h(d) = h(e) = 3$ i $h(f) = 0$. Stanje a je početno stanje, a stanje f je ciljno stanje. **Za koju vrijednost heuristike za stanje b** algoritam "uspona na vrh" *ne* pronalazi optimalno rješenje, ali ga algoritam "najbolji prvi" pronalazi?

A $h(b) = 0$ B $h(b) = 5$ C $h(b) = 4$ D $h(b) = 3$

2 (R) Razmatramo igru za dva igrača sa sumom nula. Svako stanje $s \in S$ te igre može se sažeto opisati troznamenkastim prirodnim brojem između 111 i 999. Sljedbenička stanja od s jesu sva ona stanja koja se dobivaju iz s tako da se jedna znamenka poveća za jedan, npr., $succ(235) = \{335, 245, 236\}$. Međutim, stanja koja sadrže znamenku 9 su završna stanja i ona nemaju sljedbeničkih stanja, npr., $succ(932) = \emptyset$. U završnim stanjima, isplata za prvog igrača (MAX) jednaka je razlici prve i treće znamenke, npr., $utility(932) = 9 - 2 = 7$. Isplata za drugog igrača (MIN) je negativna vrijednost isplate za prvog igrača. U igri se natječu dva algoritma minimax, A_1 (igrač MAX) i A_2 (igrač MIN). Oba algoritma pretražuju do dva poteza unaprijed, tj. dubinsko ograničenje algoritma minimax jednako je 2. Međutim, algoritmi koriste različite heuristike. Heuristika h_1 algoritma A_1 jednaka je prvoj znamenci iz s, a heuristika h_2 algorithma A_2 (definirana iz perspektive tog algoritma) jednaka je trećoj znamenci iz s. Npr., $h_1(236) = 2$ i $h_2(236) = 6$ (kod izračuna minimax vrijednosti u stablu sa MAX korijenom vrijednost heuristike h_2 trebate negirati). Početno stanje igre neka je $s_0 = 175$. Prvi potez vuče algoritam A_1 (igrač MAX). **Koji je slijed stanja igre, ako oba igrača vuku svoje minimax-optimalne poteze?**

A $175 \to 275 \to 375$ B $175 \to 176 \to 186$ C $175 \to 275 \to 276$ D $175 \to 176 \to 276$

3 (R) Neka su definirani skup stanja $S = \{a, b, c, d, e, f\}$ i funkcija sljedbenika $succ(a) = \{(b, 1), (c, 2)\}$, $succ(b) = succ(f) = \emptyset$, $succ(c) = \{(d, 3), (e, 5)\}$, $succ(d) = \{(b, 8), (f, 5)\}$, te $succ(e) = \{(d, 1), (f, 2)\}$. Heurističke vrijednosti čvorova neka su $h(a) = 7$, $h(b) = 4$, $h(c) = 6$, $h(d) = h(e) = 2$, $h(f) = 0$. Početno stanje neka je a, a ciljno f. Izvršite pretraživanje algoritmom A^*, bilježeći pritom sadržaje liste otvorenih čvorova O i zatvorenih čvorova C u svakom koraku algoritma (u nultom koraku $O = [(a, 0)]$ i $C = \emptyset$). **Koji su sadržaji listi O i C nakon petog koraka izvođenja algoritma A^*?**

A $O = [(e, 7), (f, 10)]$, $C = \{(a, 0), (c, 2), (d, 5)\}$

B Algoritam ne dostiže peti korak

C $O = [(e, 7), (f, 10), (b, 13)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5)\}$

D $O = [(f, 9)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5), (e, 7)\}$

4 (T) Složenost problema pretraživanja prostora stanja opisali smo parametrima $|S|$, b, d i m. O tim parametrima ovisi kako će se neki algoritam pretraživanja ponašati na dotičnom problemu. Neka je k konačan prirodan broj. **U kojem slučaju će nepotpun algoritam sigurno terminirati (završiti s izvođenjem)?**

A $d = |S| + k$ B $m = d + k$ C $b \leq m \cdot k$ D $b < k \cdot |S|$

2. Prikazivanje znanja i automatsko zaključivanje (4 pitanja)

5 (R) Želimo dokazati sljedeću relaciju deduktivne posljedice:

$$\forall x\Big(P(x,a) \rightarrow \neg\forall y\big(Q(y) \rightarrow \exists z R(z,y)\big)\Big),\ \exists x\forall y\Big(Q(y) \rightarrow R(x,y)\Big)\ \vdash\ \exists x\neg P(c,x).$$

Pretvorite premise i negaciju ciljne formule u klauzalni oblik te primijenite rezoluciju opovrgavanjem uz strategiju skupa potpore (SoS). **Koliko klauzula ulazi u postupak te je li cilj dokaziv i u koliko rezolucijskih koraka?**

- A 3 klauzule; nije dokazivo
- B 5 klauzula; dokazivo u 2 koraka
- C 5 klauzula; dokazivo u 3 koraka
- D 4 klauzule; dokazivo u 4 koraka

6 (P) Neka $F \equiv P \wedge \Big((P \rightarrow S) \wedge (S \rightarrow U)\Big)$ i $G \equiv F \wedge \neg S$. **Što od sljedećeg vrijedi za formule F i G?**

- A Obje formule su zadovoljive (konzistentne)
- B F je tautologija, a G nije
- C F je zadovoljiva (konzistentna), a G nije
- D Obje formule su tautologije

7 (T) Postupak rezolucije u logici prvog reda (FOL) oslanja se na algoritam najopćenitijeg zajedničkog unifikatora (MGU). **Što je rezultat algoritma MGU, u slučaju kada se dva izraza mogu unificirati?**

- A Neprazan skup atoma i varijabli FOL
- B Rezolventa ili prazna (nil) klauzula
- C Skup parova izraza i varijabli FOL
- D Formula FOL u obliku disjunkcije konjunkcija

8 (T) Kod prikazivanja znanja formalnom logikom postoji kompromis između ekspresivnosti i odlučivosti sustava logike. **Što to točno znači?**

- A Što je u logičkom sustavu veći skup epistemičkih pretpostavki, to je manji skup ontoloških pretpostavki
- B Logički sustav koji može vrlo detaljno opisati stvarni svijet ne može izvesti mnoge logičke posljedice
- C Uključivanjem varijabli logički sustav može opisati relacije između objekata, ali postaje nepotpun
- D U logičkom sustavu s potpunim skupom pravila zaključivanja neke logičke posljedice ne možemo dokazati

3. Logičko programiranje i ekspertni sustavi (2 pitanja)

9 (R) Baza znanja ekspertnog sustava sadrži sljedeća pravila:

(1) AKO $(A = a_2) \wedge (D = d_2)$ ONDA $C = c_1$
(2) AKO $(F = f_3) \vee (B = b_3)$ ONDA $C = c_2$
(3) AKO $(E = e_1) \vee (B = b_1)$ ONDA $(A = a_1) \wedge (D = d_2)$
(4) AKO $F = f_1$ ONDA $D = d_2$
(5) AKO $F = f_2$ ONDA $E = e_2$
(6) AKO $(B = b_3) \vee (D = d_1)$ ONDA $(E = e_1) \wedge (A = a_2)$

Sustav koristimo za izvođenje vrijednosti varijable C ulančavanjem unazad. Prednost imaju pravila s manjim rednim brojem. Pravila koja su jednom palila više ne mogu paliti. Jednom izvedeni međuciljevi brišu se sa stoga, neovisno o njihovoj poziciji na stogu. Na moguće upite od strane sustava, korisnik odgovara sa $B = b_3$ i $F = f_1$. **Što radi ekspertni sustav pri izvođenju vrijednosti varijable C?**

- A Odbacuje pravilo 2 te kasnije pali pravilo 5
- B Pali tri pravila i izvodi $C = c_2$
- C Pali četiri pravila i izvodi $C = c_1$
- D Odbacuje pravilo 6 te kasnije pali pravilo 3

10 (T) Semantika operatora negacije u Prologu (operator `not`) temelji se na pretpostavci zatvorenog svijeta. **Što ta pretpostavka znači?**

- A U bazu se ne mogu dodavati nove činjenice
- B Dokazane činjenice ne mogu se opovrgnuti
- C Sve što ne slijedi iz baze znanja je lažno
- D Svaka istinita činjenica može se dokazati

4. Modeliranje neizvjesnosti (2 pitanja)

11 (P) Razmotrimo jezičnu varijablu *starost kanarinca*, definiranu s izrazima *mlad* i *star*. Značenje tih izraza modeliramo neizrazitim skupovima M odnosno S, definiranima nad univerzalnim skupom $\mathbb{R}^+$, koji odgovara godinama. Funkcije pripadnosti μ_M i μ_S definiramo kao po dijelovima linearne funkcije. Funkcija $\mu_M(x)$ ima vrijednost 1 za $0 \leq x \leq 5$, vrijednost 0 za $x \geq 9$, te linearno pada za $5 < x < 9$. Funkcija $\mu_S(x)$ ima vrijednost 0 za $0 \leq x \leq 6$, vrijednost 1 za $x \geq 12$, te linearno raste za $6 < x < 12$. Uporabom Zadehovih operatora definiramo dva neizrazita skupa: skup X_1 sa značenjem *mlad ili star kanarinac* te skup X_2 sa značenjem *mlad ili ne mlad kanarinac*. **Za koje se sve elemente $x \in \mathbb{R}^+$ pripadnost ovim dvama neizrazitim skupovima razlikuje?**

A $7 \leq x \leq 9$ B $7 \leq x \leq 12$ C $9 \leq x \leq 12$ D $5 \leq x \leq 6$

12 (T) Bayesovo pravilo čini temelj vjerojatnosnog modeliranja neizvjesnog znanja. **Koju vjerojatnost modelira Bayesovo pravilo, i kako?**

A Uvjetnu vjerojatnost hipoteze uz predočen dokaz na temelju (1) uvjetne vjerojatnost dokaza uz predočenu hipotezu i (2) vjerojatnosti hipoteze prije predočavanja dokaza

B Združenu vjerojatnost hipoteze i dokaza na temelju (1) uvjetne vjerojatnosti dokaza u predočenu hipotezu i (2) vjerojatnosti dokaza neovisno o hipotezi

C Uvjetnu vjerojatnost dokaza uz predočenu hipotezu na temelju (1) vjerojatnosti hipoteze prije predočavanja dokaza i (2) vjerojatnosti dokaza neovisno o hipotezi

D Vjerojatnost hipoteze prije predočavanja dokaza na temelju (1) vjerojatnosti hipoteze uz predočen dokaz i (2) združene vjerojatnosti dokaza i hipoteze

5. Strojno učenje, umjetne neuronske mreže i podržano učenje (5 pitanja)

13 (P) Radimo svoju implementaciju algoritma ID3. Kako bismo spriječili da se model prenauči, implementirali smo i podrezivanje stabla na dubini k. Nažalost, kod implementacije funkcije informacijske dobiti (IG) potkrala nam se mala pogreška: zaboravili smo negirati vrijednost pri izračunu entropije $E(D)$ skupa primjera D. Dakle, umjesto da izračunava $E(D)$, naša implementacija izračunava $-E(D)$. Neka je M_1^k stablo odluke koje dobivamo učenjem takvim pogrešno implementiranim algoritmom ID3, podrezano na neku konačnu dubinu k. Neka je M_2^k stablo koje bismo dobili da smo algoritam ID3 implementirali ispravno i naučeno stablo podrezali na neku konačnu dubinu k. Ako $k = \infty$, onda to znači da stablo ne podrezujemo. Neka je $E_u(M)$ pogreška učenja modela M, a $E_p(M)$ pogreška modela M na skupu za provjeru. **Što od sljedećeg možemo očekivati da vrijedi?**

A $E_p(M_1^\infty) < E_p(M_2^\infty)$ B $E_p(M_1^\infty) > E_p(M_2^\infty)$ C $E_p(M_2^k) < E_u(M_2^k)$ D $E_u(M_1^k) < E_u(M_1^\infty)$

14 (T) Algoritam propagacije pogreške unazad (engl. *backpropagation algorithm*) rješava problem dodjele odgovornosti pojedinih neurona mreže. Preciznije, algoritam definira kako izračunati pogrešku $\delta_i^{(k)}$ neurona i u sloju k, gdje je k bilo koji skriveni sloj mreže. **O čemu ovisi pogreška $\delta_i^{(k)}$?**

A O pogreškama svih neurona u sloju $k + 1$ (sloj bliže izlazu) čiji su ulazi povezani s izlazom neurona i

B O izlazima svih neurona u slojevima $k - 1$ (sloj bliže ulazu) čiji su izlazi povezani s ulazom neurona i

C O pogreškama svih neurona u sloju k čiji su izlazi izravno ili neizravno povezani s neuronima izlaznog sloja

D O razlici ostvarnog i ciljanog izlaza, $t_j - o_j$, za sve neurone j u skrivenom sloju $k - 1$ (sloj bliže ulazu)

15 (R) Skup primjera za učenje $\{(x_2, x_1, y)\}$ je $\{(1, 1, -1), (2, 4, 1), (1, 2, -1), (3, 3, 1), (2, 1, -1), (4, 2, 1)\}$. Učenje se provodi uporabom perceptrona TLU s izlaznim vrijednostima -1 i 1 te stopom učenja $\eta = 1$. Početne vrijednosti težinskih faktora su $(w_2, w_1, w_0) = (1.3, -1.2, -10)$. Provedite postupak učenja Rosenblattovim algoritmom. **Koliko se puta tijekom učenja provode korekcije težina te koje su njihove konačne vrijednosti?**

A 2 puta, $(-1.1, 0.8, -6.9)$ B 2 puta, $(3.3, 2.8, -10)$ C 3 puta, $(1.3, 1.2, -5.2)$ D 3 puta, $(-5.2, 0.7, 1.2)$

16 (R) Treniramo naivan Bayesov klasifikator za *"Skupo ljetovanje na Jadranu"*. Skup za učenje je sljedeći:

i	Mjesto	Otok	Smještaj	Prijevoz	y	i	Mjesto	Otok	Smještaj	Prijevoz	y
1	Kvarner	da	privatni	auto	1	5	Kvarner	ne	kamp	bus	0
2	Dalmacija	da	hotel	avion	1	6	Dalmacija	ne	privatni	avion	0
3	Istra	da	kamp	auto	0	7	Istra	ne	kamp	bus	1
4	Dalmacija	da	hotel	auto	1						

Procjene radimo Laplaceovim procjeniteljem "dodaj jedan". Klasificiramo primjer $\mathbf{x} = (\text{Istra}, \text{ne}, \text{kamp}, \text{bus})$. **Koliko iznosi aposteriorna vjerojatnost** $P(y = 1|\mathbf{x})$**?**

A 0.237 B 0.318 C 0.706 D 0.685

17 (P) Rešetkasti svijet sastoji se od četiri ćelije, označene brojevima 1 do 4 i poredane vodoravno slijeva nadesno. Ćelija 4 je terminalna i agentu donosi 1 bod; nema drugih bodova. Svijet je okružen zidovima. Agent može poduzeti akcije *lijevo* i *desno*. Ako bi ga akcija dovela na zid, ostaje u ćeliji u kojoj je bio. Agent uvijek kreće iz ćelije 1. Provodimo postupak Q-učenja. Početni iznosi Q-funkcije su 0. Parametri su $\alpha = 0.5$ i $\gamma = 1$. Agent najprije igra tri epizode u kojima uvijek bira akciju *desno* i uči. Nakon toga igra još 10 epizoda u kojima u svakoj ćeliji pohlepno odabire potez koji mu se čini optimalan i također uči. **Nakon provedenih svih 13 epizoda, koja je očekivana vrijednost** $q(3, \textit{desno})$**?**

A Između 0.75 i 0.9995 B Nije moguće odgovoriti C Manja od 0.75 D Veća od 0.9995

6. Prirodom inspirirani optimizacijski algoritmi (3 pitanja)

18 (P) Ako kod algoritma Ant System postavimo parametre $\alpha = 0$ i $\beta = 1$, **što će biti posljedica?**

A Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo količini feromonskih tragova

B Vjerojatnost odabira nekog brida neće ovisiti o feromonskim tragovima

C Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo heurističkoj informaciji

D U algoritmu se neće događati isparavanje feromonskih tragova

19 (R) Generacijskim genetskim algoritmom tražimo maksimum funkcije $f(x, y) = 20 - (x - 3)^2 - (y - 4)^2$. Kao reprezentaciju rješenja koristimo 6-bitovni kromosom, pri čemu se prva tri bita koriste za kodiranje vrijednosti varijable x, a preostala tri bita za kodiranje vrijednosti varijable y. Domena nad kojom se pretražuju vrijednosti od x je $[1, 8]$ te od y je $[0, 7]$. Populacija se sastoji od četiri jedinke: J1=000110, J2=011001, J3=100111, J4=001110. Pretpostavite da se roditelji biraju proporcionalnom selekcijom te da su u jednom koraku kao roditelji izvučena dva rješenja koja imaju najmanju vjerojatnost odabira. Provedite nad njima postupak križanja s jednom točkom prijeloma (točka prijeloma je nakon prva dva bita); pretpostavite da u ovom koraku operator mutacije svaki puta djeluje na posljednja dva bita kromosoma. **Odredite iznos funkcije** f **u rješenju koje odgovara djetetu koje će biti poslano u sljedeću generaciju.** (Ako ih operatori križanja i mutacije generiraju više, u novu generaciju treba proslijediti najbolje.)

A 11 B 18 C 20 D 7

20 (T) Genetički algoritmi oponašaju proces biološke evolucije te implementiraju operatore selekcije, križanja i mutacije. Neka je P populacija kromosoma te neka je $\mathcal{P}$ skup svih populacija. Neka operatori selekcije, križanja i mutacije odgovaraju funkcijama s, k, odnosno m. **Kako možemo formalno opisati preslikavanja koja obavljaju te funkcije?**

A $s : \mathcal{P} \to P$, $k : P \times P \to P$, $m : P \to P \times P$

B $s : \mathcal{P} \to P \times P \times P$, $k : P \times P \to \mathcal{P}$, $m : P \times P \to P$

C $s : \mathcal{P} \to P \times P$, $k : P \times P \to P \times P$, $m : P \to P$

D $s : P \to \mathcal{P}$, $k : P \times P \to P$, $m : P \times P \to \mathcal{P}$

Uvod u umjetnu inteligenciju – pismeni ispit (2021./2022.)

– NEKORIGIRANA VERZIJA –

*Ispit se sastoji od **20 pitanja** i ukupno nosi **20 bodova**. Točan odgovor nosi 1 bod a netočan -1/3 boda. Trajanje ispita je **150 minuta**. Primjerak ispita trebate predati zajedno sa svojim rješenjima.*

1. Pretraživanje prostora stanja i igranje igara (4 pitanja)

1 (R) Neka su definirani skup stanja $S = \{a, b, c, d, e, f\}$ i funkcija sljedbenika $succ(a) = \{(b, 1), (c, 2)\}$, $succ(b) = succ(f) = \emptyset$, $succ(c) = \{(d, 3), (e, 5)\}$, $succ(d) = \{(b, 8), (f, 5)\}$, te $succ(e) = \{(d, 1), (f, 2)\}$. Heurističke vrijednosti čvorova neka su $h(a) = 7$, $h(b) = 4$, $h(c) = 6$, $h(d) = h(e) = 2$, $h(f) = 0$. Početno stanje neka je a, a ciljno f. Izvršite pretraživanje algoritmom A^*, bilježeći pritom sadržaje liste otvorenih čvorova O i zatvorenih čvorova C u svakom koraku algoritma (u nultom koraku $O = [(a, 0)]$ i $C = \emptyset$). **Koji su sadržaji listi O i C nakon četvrtog koraka izvođenja algoritma A^*?**

- A $O = [(f, 9)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5)\}$
- B $O = [(e, 7), (f, 10)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5)\}$
- C $O = [(e, 7), (f, 10)]$, $C = \{(a, 0), (c, 2), (d, 5)\}$
- D Algoritam ne dostiže četvrti korak

2 (R) Razmatramo igru za dva igrača sa sumom nula. Svako stanje $s \in S$ te igre može se sažeto opisati troznamenkastim prirodnim brojem između 111 i 999. Sljedbenička stanja od s jesu sva ona stanja koja se dobivaju iz s tako da se jedna znamenka poveća za jedan, npr., $succ(235) = \{335, 245, 236\}$. Međutim, stanja koja sadrže znamenku 9 su završna stanja i ona nemaju sljedbeničkih stanja, npr., $succ(932) = \emptyset$. U završnim stanjima, isplata za prvog igrača (MAX) jednaka je razlici prve i treće znamenke, npr., $utility(932) = 9 - 2 = 7$. Isplata za drugog igrača (MIN) je negativna vrijednost isplate za prvog igrača. U igri se natječu dva algoritma minimax, A_1 (igrač MAX) i A_2 (igrač MIN). Oba algoritma pretražuju do dva poteza unaprijed, tj. dubinsko ograničenje algoritma minimax jednako je 2. Međutim, algoritmi koriste različite heuristike. Heuristika h_1 algoritma A_1 jednaka je trećoj znamenci iz s, a heuristika h_2 algorithma A_2 (definirana iz perspektive tog algoritma) jednaka je prvoj znamenci iz s. Npr., $h_1(236) = 6$ i $h_2(236) = 2$ (kod izračuna minimax vrijednosti u stablu sa MAX korijenom vrijednost heuristike h_2 trebate negirati). Početno stanje igre neka je $s_0 = 175$. Prvi potez vuče algoritam A_1 (igrač MAX). **Koji je slijed stanja igre, ako oba igrača vuku svoje minimax-optimalne poteze?**

- A $175 \to 176 \to 186$
- B $175 \to 275 \to 276$
- C $175 \to 275 \to 375$
- D $175 \to 176 \to 276$

3 (T) Složenost problema pretraživanja prostora stanja opisali smo parametrima $|S|$, b, d i m. O tim parametrima ovisi kako će se neki algoritam pretraživanja ponašati na dotičnom problemu. Neka je k konačan prirodan broj. **U kojem slučaju će nepotpun algoritam sigurno terminirati (završiti s izvođenjem)?**

- A $m = d + k$
- B $b \leq m \cdot k$
- C $b < k \cdot |S|$
- D $d = |S| + k$

4 (P) Poželjno svojstvo aloritma pretraživanja jest da je optimalan. Međutim, algoritmi "najbolji prvi" i "uspon na vrh" nisu optimalni. Oba su ova algoritma "pohlepna", ali je algoritam "najbolji prvi" manje pohlepan od algoritma "uspon na vrh", pa u praksi postoji veća vjerojatnost da će algoritam "najboji prvi" pronaći optimalan put. Skicirajte prostor stanja $S = \{a, b, c, d, e, f\}$ s prijelazima $succ(a) = \{b, c\}$, $succ(b) = \{d, e\}$, $succ(c) = succ(d) = succ(e) = \{f\}$. Cijene svih prijelaza su jednake i iznose 1. Heuristika neka je $h(b) = 1$, $h(d) = h(e) = 3$ i $h(f) = 0$. Stanje a je početno stanje, a stanje f je ciljno stanje. **Za koju vrijednost heuristike za stanje c** algoritam "uspona na vrh" *ne* pronalazi optimalno rješenje, ali ga algoritam "najbolji prvi" pronalazi?

- A $h(c) = 0$
- B $h(c) = 4$
- C $h(c) = 5$
- D $h(c) = 2$

2. Prikazivanje znanja i automatsko zaključivanje (4 pitanja)

5 (R) Želimo dokazati sljedeću relaciju deduktivne posljedice:

$$\forall x\Big(P(x, a) \to \neg\forall y\big(Q(y) \to \exists z R(z, y)\big)\Big),\ \exists x \forall y\Big(Q(y) \to R(x, y)\Big)\ \vdash\ \exists x \neg\Big(P(c, x) \land R(x, c)\Big).$$

Pretvorite premise i negaciju ciljne formule u klauzalni oblik te primijenite rezoluciju opovrgavanjem uz strategiju skupa potpore (SoS). **Koliko klauzula ulazi u postupak te je li cilj dokaziv i u koliko rezolucijskih koraka?**

A 4 klauzule; dokazivo u 4 koraka
B 5 klauzula; dokazivo u 4 koraka
C 3 klauzule; dokazivo u 2 koraka
D 3 klauzule; nije dokazivo

6 (T) Postupak rezolucije u logici prvog reda (FOL) oslanja se na algoritam najopćenitijeg zajedničkog unifikatora (MGU). **Što je rezultat algoritma MGU, u slučaju kada se dva izraza mogu unificirati?**

A Formula FOL u obliku disjunkcije konjunkcija
B Rezolventa ili prazna (nil) klauzula
C Skup parova izraza i varijabli FOL
D Neprazan skup atoma i varijabli FOL

7 (P) Neka $F \equiv P \wedge \Big((P \rightarrow S) \wedge (S \rightarrow U)\Big)$ i $G \equiv F \wedge \neg S$. **Što od sljedećeg vrijedi za formule F i G?**

A Obje formule su zadovoljive (konzistentne)
B F je zadovoljiva (konzistentna), a G nije
C G je zadovoljiva (konzistentna), a F nije
D G je tautologija, a F nije

8 (T) Kod prikazivanja znanja formalnom logikom postoji kompromis između ekspresivnosti i odlučivosti sustava logike. **Što to točno znači?**

A Uključivanjem varijabli logički sustav može opisati relacije između objekata, ali postaje nepotpun
B U logičkom sustavu s potpunim skupom pravila zaključivanja neke logičke posljedice ne možemo dokazati
C Što je u logičkom sustavu veći skup epistemičkih pretpostavki, to je manji skup ontoloških pretpostavki
D Logički sustav koji može vrlo detaljno opisati stvarni svijet ne može izvesti mnoge logičke posljedice

3. Logičko programiranje i ekspertni sustavi (2 pitanja)

9 (T) Semantika operatora negacije u Prologu (operator `not`) temelji se na pretpostavci zatvorenog svijeta. **Što ta pretpostavka znači?**

A Baza sadržava isključivo temeljne atome
B Sve što ne slijedi iz baze znanja je lažno
C Pravilo *modus ponens* je potpuno
D Svaka istinita činjenica može se dokazati

10 (R) Baza znanja ekspertnog sustava sadrži sljedeća pravila:

(1) AKO $(A = a_2) \wedge (D = d_2)$ ONDA $C = c_1$
(2) AKO $(F = f_3) \vee (B = b_3)$ ONDA $C = c_2$
(3) AKO $(E = e_1) \vee (B = b_1)$ ONDA $(A = a_1) \wedge (D = d_2)$
(4) AKO $F = f_1$ ONDA $D = d_2$
(5) AKO $F = f_2$ ONDA $E = e_2$
(6) AKO $(B = b_3) \vee (D = d_1)$ ONDA $(E = e_1) \wedge (A = a_2)$

Sustav koristimo za izvođenje vrijednosti varijable C ulančavanjem unazad. Prednost imaju pravila s manjim rednim brojem. Pravila koja su jednom palila više ne mogu paliti. Jednom izvedeni međuciljevi brišu se sa stoga, neovisno o njihovoj poziciji na stogu. Na možebitne upite od strane sustava, korisnik odgovara sa $B = b_3$ i $F = f_1$. **Što radi ekspertni sustav pri izvođenju vrijednosti varijable C?**

A Odbacuje pravilo 3 te kasnije pali pravilo 4
B Završava s četiri činjenice u radnoj memoriji
C Pali pet pravila i izvodi $C = c_1$
D Odbacuje pravilo 5 te kasnije pali pravilo 6

4. Modeliranje neizvjesnosti (2 pitanja)

11 (T) Bayesovo pravilo čini temelj vjerojatnosnog modeliranja neizvjesnog znanja. **Koju vjerojatnost modelira Bayesovo pravilo, i kako?**

A Vjerojatnost hipoteze prije predočavanja dokaza na temelju (1) vjerojatnosti hipoteze uz predočen dokaz i (2) združene vjerojatnosti dokaza i hipoteze
B Uvjetnu vjerojatnost hipoteze uz predočen dokaz na temelju (1) uvjetne vjerojatnost dokaza uz predočenu hipotezu i (2) vjerojatnosti hipoteze prije predočavanja dokaza
C Uvjetnu vjerojatnost dokaza uz predočenu hipotezu na temelju (1) vjerojatnosti hipoteze prije predočavanja dokaza i (2) vjerojatnosti dokaza neovisno o hipotezi
D Združenu vjerojatnost hipoteze i dokaza na temelju (1) uvjetne vjerojatnosti dokaza u predočenu hipotezu i (2) vjerojatnosti dokaza neovisno o hipotezi

12 (P) Razmotrimo jezičnu varijablu *starost kanarinca*, definiranu s izrazima *mlad* i *star*. Značenje tih izraza modeliramo neizrazitim skupovima M odnosno S, definiranima nad univerzalnim skupom $\mathbb{R}^+$, koji odgovara godinama. Funkcije pripadnosti μ_M i μ_S definiramo kao po dijelovima linearne funkcije. Funkcija $\mu_M(x)$ ima vrijednost 1 za $0 \leq x \leq 5$, vrijednost 0 za $x \geq 9$, te linearno pada za $5 < x < 9$. Funkcija $\mu_S(x)$ ima vrijednost 0 za $0 \leq x \leq 6$, vrijednost 1 za $x \geq 12$, te linearno raste za $6 < x < 12$. Uporabom Zadehovih operatora definiramo dva neizrazita skupa: skup X_1 sa značenjem *mlad ili star kanarinac* te skup X_2 sa značenjem *mlad ili ne mlad kanarinac*. **Za koje se sve elemente $x \in \mathbb{R}^+$ pripadnost ovim dvama neizrazitim skupovima razlikuje?**

A $7 \leq x \leq 12$ B $9 \leq x \leq 12$ C $7 \leq x \leq 9$ D $5 \leq x \leq 6$

5. Strojno učenje, umjetne neuronske mreže i podržano učenje (5 pitanja)

13 (R) Treniramo naivan Bayesov klasifikator za *"Skupo ljetovanje na Jadranu"*. Skup za učenje je sljedeći:

i	Mjesto	Otok	Smještaj	Prijevoz	y	i	Mjesto	Otok	Smještaj	Prijevoz	y
1	Kvarner	da	privatni	auto	1	5	Kvarner	ne	kamp	bus	0
2	Dalmacija	da	hotel	avion	1	6	Dalmacija	ne	privatni	avion	0
3	Istra	da	kamp	auto	0	7	Istra	ne	kamp	bus	1
4	Dalmacija	da	hotel	auto	1						

Procjene radimo Laplaceovim procjeniteljem "dodaj jedan". Klasificiramo primjer $\mathbf{x} = (\text{Dalmacija}, \text{ne}, \text{kamp}, \text{bus})$. **Koliko iznosi aposteriorna vjerojatnost $P(y = 1|\mathbf{x})$?**

A 0.318 B 0.706 C 0.685 D 0.237

14 (P) Radimo svoju implementaciju algoritma ID3. Kako bismo spriječili da se model prenauči, implementirali smo i podrezivanje stabla na dubini k. Nažalost, kod implementacije funkcije informacijske dobiti (IG) potkrala nam se mala pogreška: zaboravili smo negirati vrijednost pri izračunu entropije $E(D)$ skupa primjera D. Dakle, umjesto da izračunava $E(D)$, naša implementacija izračunava $-E(D)$. Neka je M_1^k stablo odluke koje dobivamo učenjem takvim pogrešno implementiranim algoritmom ID3, podrezano na neku konačnu dubinu k. Neka je M_2^k stablo koje bismo dobili da smo algoritam ID3 implementirali ispravno i naučeno stablo podrezali na neku konačnu dubinu k. Ako $k = \infty$, onda to znači da stablo ne podrezujemo. Neka je $E_u(M)$ pogreška učenja modela M, a $E_p(M)$ pogreška modela M na skupu za provjeru. **Što od sljedećeg možemo očekivati da vrijedi?**

A $E_p(M_1^\infty) = E_u(M_1^\infty)$ B $E_p(M_1^k) < E_u(M_1^k)$ C $E_p(M_1^k) > E_p(M_2^k)$ D $E_p(M_1^\infty) < E_u(M_1^\infty)$

15 (T) Algoritam propagacije pogreške unazad (engl. *backpropagation algorithm*) rješava problem dodjele odgovornosti pojedinih neurona mreže. Preciznije, algoritam definira kako izračunati pogrešku $\delta_i^{(k)}$ neurona i u sloju k, gdje je k bilo koji skriveni sloj mreže. **O čemu ovisi pogreška $\delta_i^{(k)}$?**

A O pogreškama svih neurona u sloju k čiji su izlazi izravno ili neizravno povezani s neuronima izlaznog sloja

B O pogreškama svih neurona u sloju $k+1$ (sloj bliže izlazu) čiji su ulazi povezani s izlazom neurona i

C O izlazima svih neurona u slojevima $k-1$ (sloj bliže ulazu) čiji su izlazi povezani s ulazom neurona i

D O razlici ostvarnog i ciljanog izlaza, $t_j - o_j$, za sve neurone j u skrivenom sloju $k-1$ (sloj bliže ulazu)

16 (R) Skup primjera za učenje $\{(x_2, x_1, y)\}$ je $\big\{(1,1,-1),(2,4,1),(1,2,-1),(3,3,1),(2,1,-1),(4,2,1)\big\}$. Učenje se provodi uporabom perceptrona TLU s izlaznim vrijednostima -1 i 1 te stopom učenja $\eta = 1$. Početne vrijednosti težinskih faktora su $(w_2, w_1, w_0) = (1.3, 1.2, -3.2)$. Provedite postupak učenja Rosenblattovim algoritmom. **Koliko se puta tijekom učenja provode korekcije težina te koje su njihove konačne vrijednosti?**

A 3 puta, $(-5.2, 0.7, 1.2)$ B Postupak ne konvergira C 4 puta, $(1.3, -2.5, 12)$ D 3 puta, $(1.3, 1.2, -5.2)$

17 (P) Rešetkasti svijet sastoji se od četiri ćelije, označene brojevima 1 do 4 i poredane vodoravno slijeva nadesno. Ćelija 4 je terminalna i agentu donosi 1 bod; nema drugih bodova. Svijet je okružen zidovima. Agent može poduzeti akcije *lijevo* i *desno*. Ako bi ga akcija dovela na zid, ostaje u ćeliji u kojoj je bio. Agent uvijek kreće iz ćelije 1. Provodimo postupak Q-učenja. Početni iznosi Q-funkcije su 0. Parametri su $\alpha = 0.5$ i $\gamma = 1$. Agent najprije igra tri epizode u kojima uvijek bira akciju *desno* i uči. Nakon toga igra još 10 epizoda u kojima u svakoj ćeliji pohlepno odabire potez koji mu se čini optimalan i također uči. **Nakon provedenih svih 13 epizoda, koja je očekivana vrijednost $q(3, \textit{desno})$?**

A Nije moguće odgovoriti B Veća od 0.9995 C Manja od 0.75 D Između 0.75 i 0.9995

6. Prirodom inspirirani optimizacijski algoritmi (3 pitanja)

18 (P) Ako kod algoritma Ant System postavimo parametre $\alpha = 1$ i $\beta = 0$, **što će biti posljedica?**

- A Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo količini feromonskih tragova
- B Vjerojatnost odabira nekog brida neće ovisiti o feromonskim tragovima
- C U algoritmu se neće događati isparavanje feromonskih tragova
- D Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo heurističkoj informaciji

19 (T) Genetički algoritmi oponašaju proces biološke evolucije te implementiraju operatore selekcije, križanja i mutacije. Neka je P populacija kromosoma te neka je $\mathcal{P}$ skup svih populacija. Neka operatori selekcije, križanja i mutacije odgovaraju funkcijama s, k, odnosno m. **Kako možemo formalno opisati preslikavanja koja obavljaju te funkcije?**

- A $s : \mathcal{P} \to P \times P \times P$, $k : P \times P \to \mathcal{P}$, $m : P \times P \to P$
- B $s : \mathcal{P} \to P$, $k : P \times P \to P$, $m : P \to P \times P$
- C $s : \mathcal{P} \to P \times P$, $k : P \times P \to P \times P$, $m : P \to P$
- D $s : P \to \mathcal{P}$, $k : P \times P \to P$, $m : P \times P \to \mathcal{P}$

20 (R) Generacijskim genetskim algoritmom tražimo maksimum funkcije $f(x, y) = 18 - (x - 4)^2 - (y - 2)^2$. Kao reprezentaciju rješenja koristimo 6-bitovni kromosom, pri čemu se prva tri bita koriste za kodiranje vrijednosti varijable x, a preostala tri bita za kodiranje vrijednosti varijable y. Domena nad kojom se pretražuju vrijednosti od x je $[2, 9]$ te od y je $[-2, 5]$. Populacija se sastoji od četiri jedinke: J1=000110, J2=011001, J3=100111, J4=001110. Pretpostavite da se roditelji biraju proporcionalnom selekcijom te da su u jednom koraku kao roditelji izvučena dva rješenja koja imaju najmanju vjerojatnost odabira. Provedite nad njima postupak križanja s jednom točkom prijeloma (točka prijeloma je nakon prva dva bita); pretpostavite da u ovom koraku operator mutacije svaki puta djeluje na posljednja dva bita kromosoma. **Odredite iznos funkcije f u rješenju koje odgovara djetetu koje će biti poslano u sljedeću generaciju.** (Ako ih operatori križanja i mutacije generiraju više, u novu generaciju treba proslijediti najbolje.)

A 16 B 18 C 5 D 9

Uvod u umjetnu inteligenciju – pismeni ispit (2021./2022.)

– NEKORIGIRANA VERZIJA –

*Ispit se sastoji od **20 pitanja** i ukupno nosi **20 bodova**. Točan odgovor nosi 1 bod a netočan -1/3 boda. Trajanje ispita je **150 minuta**. Primjerak ispita trebate predati zajedno sa svojim rješenjima.*

1. Pretraživanje prostora stanja i igranje igara (4 pitanja)

1 (T) Složenost problema pretraživanja prostora stanja opisali smo parametrima $|S|$, b, d i m. O tim parametrima ovisi kako će se neki algoritam pretraživanja ponašati na dotičnom problemu. Neka je k konačan prirodan broj. **U kojem slučaju će nepotpun algoritam sigurno terminirati (završiti s izvođenjem)?**

A $d = |S| + k$ B $b < k \cdot |S|$ C $b \leq m \cdot k$ D $m = d + k$

2 (R) Razmatramo igru za dva igrača sa sumom nula. Svako stanje $s \in S$ te igre može se sažeto opisati troznamenkastim prirodnim brojem između 111 i 999. Sljedbenička stanja od s jesu sva ona stanja koja se dobivaju iz s tako da se jedna znamenka poveća za jedan, npr., $succ(235) = \{335, 245, 236\}$. Međutim, stanja koja sadrže znamenku 9 su završna stanja i ona nemaju sljedbeničkih stanja, npr., $succ(932) = \emptyset$. U završnim stanjima, isplata za prvog igrača (MAX) jednaka je razlici prve i treće znamenke, npr., $utility(932) = 9 - 2 = 7$. Isplata za drugog igrača (MIN) je negativna vrijednost isplate za prvog igrača. U igri se natječu dva algoritma minimax, A_1 (igrač MAX) i A_2 (igrač MIN). Oba algoritma pretražuju do dva poteza unaprijed, tj. dubinsko ograničenje algoritma minimax jednako je 2. Međutim, algoritmi koriste različite heuristike. Heuristika h_1 algoritma A_1 jednaka je prvoj znamenci iz s, a heuristika h_2 algorithma A_2 (definirana iz perspektive tog algoritma) jednaka je trećoj znamenci iz s. Npr., $h_1(236) = 2$ i $h_2(236) = 6$ (kod izračuna minimax vrijednosti u stablu sa MAX korijenom vrijednost heuristike h_2 trebate negirati). Početno stanje igre neka je $s_0 = 175$. Prvi potez vuče algoritam A_1 (igrač MAX). **Koji je slijed stanja igre, ako oba igrača vuku svoje minimax-optimalne poteze?**

A $175 \rightarrow 275 \rightarrow 276$ B $175 \rightarrow 176 \rightarrow 186$ C $175 \rightarrow 176 \rightarrow 276$ D $175 \rightarrow 275 \rightarrow 375$

3 (R) Neka su definirani skup stanja $S = \{a, b, c, d, e, f\}$ i funkcija sljedbenika $succ(a) = \{(b, 1), (c, 2)\}$, $succ(b) = succ(f) = \emptyset$, $succ(c) = \{(d, 3), (e, 5)\}$, $succ(d) = \{(b, 8), (f, 5)\}$, te $succ(e) = \{(d, 1), (f, 2)\}$. Heurističke vrijednosti čvorova neka su $h(a) = 7$, $h(b) = 4$, $h(c) = 6$, $h(d) = h(e) = 2$, $h(f) = 0$. Početno stanje neka je a, a ciljno f. Izvršite pretraživanje algoritmom A^*, bilježeći pritom sadržaje liste otvorenih čvorova O i zatvorenih čvorova C u svakom koraku algoritma (u nultom koraku $O = [(a, 0)]$ i $C = \emptyset$). **Koji su sadržaji listi O i C nakon četvrtog koraka izvođenja algoritma A^*?**

A $O = [(f, 10)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5), (e, 7)\}$

B $O = [(e, 7), (f, 10)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5)\}$

C $O = [(e, 7), (f, 10), (b, 13)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5)\}$

D Algoritam ne dostiže četvrti korak

4 (P) Poželjno svojstvo aloritma pretraživanja jest da je optimalan. Međutim, algoritmi "najbolji prvi" i "uspon na vrh" nisu optimalni. Oba su ova algoritma "pohlepna", ali je algoritam "najbolji prvi" manje pohlepan od algoritma "uspon na vrh", pa u praksi postoji veća vjerojatnost da će algoritam "najboji prvi" pronaći optimalan put. Skicirajte prostor stanja $S = \{a, b, c, d, e, f\}$ s prijelazima $succ(a) = \{b, c\}$, $succ(b) = \{d, e\}$, $succ(c) = succ(d) = succ(e) = \{f\}$. Cijene svih prijelaza su jednake i iznose 1. Heuristika neka je $h(c) = 2$, $h(d) = h(e) = 3$ i $h(f) = 0$. Stanje a je početno stanje, a stanje f je ciljno stanje. **Za koju vrijednost heuristike za stanje b** algoritam "uspona na vrh" *ne* pronalazi optimalno rješenje, ali ga algoritam "najbolji prvi" pronalazi?

A $h(b) = 1$ B $h(b) = 4$ C $h(b) = 5$ D $h(b) = 3$

2. Prikazivanje znanja i automatsko zaključivanje (4 pitanja)

5 (T) Kod prikazivanja znanja formalnom logikom postoji kompromis između ekspresivnosti i odlučivosti sustava logike. **Što to točno znači?**

- A U logičkom sustavu s potpunim skupom pravila zaključivanja neke logičke posljedice ne možemo dokazati
- B Logički sustav koji može vrlo detaljno opisati stvarni svijet ne može izvesti mnoge logičke posljedice
- C Uključivanjem varijabli logički sustav može opisati relacije između objekata, ali postaje nepotpun
- D Što je u logičkom sustavu veći skup epistemičkih pretpostavki, to je manji skup ontoloških pretpostavki

6 (P) Neka $F \equiv P \wedge \big((P \to S) \wedge (S \to U)\big)$ i $G \equiv F \wedge \neg S$. **Što od sljedećeg vrijedi za formule F i G?**

- A F je zadovoljiva (konzistentna), a G nije
- C G je zadovoljiva (konzistentna), a F nije
- B Obje formule su zadovoljive (konzistentne)
- D F je tautologija, a G nije

7 (R) Želimo dokazati sljedeću relaciju deduktivne posljedice:

$$\forall x\Big(P(x,a) \to \neg\forall y\big(Q(y) \to \exists z R(z,y)\big)\Big),\ \exists x\forall y\Big(Q(y) \to R(x,y)\Big)\ \vdash\ \exists x\neg P(c,x).$$

Pretvorite premise i negaciju ciljne formule u klauzalni oblik te primijenite rezoluciju opovrgavanjem uz strategiju skupa potpore (SoS). **Koliko klauzula ulazi u postupak te je li cilj dokaziv i u koliko rezolucijskih koraka?**

- A 5 klauzula; dokazivo u 5 koraka
- C 5 klauzula; dokazivo u 2 koraka
- B 5 klauzula; nije dokazivo
- D 4 klauzule; dokazivo u 4 koraka

8 (T) Postupak rezolucije u logici prvog reda (FOL) oslanja se na algoritam najopćenitijeg zajedničkog unifikatora (MGU). **Što je rezultat algoritma MGU, u slučaju kada se dva izraza mogu unificirati?**

- A Neprazan skup atoma i varijabli FOL
- C Rezolventa ili prazna (nil) klauzula
- B Skup parova izraza i varijabli FOL
- D Formula FOL u obliku disjunkcije konjunkcija

3. Logičko programiranje i ekspertni sustavi (2 pitanja)

9 (R) Baza znanja ekspertnog sustava sadrži sljedeća pravila:

(1) AKO $(A = a_2) \wedge (D = d_2)$ ONDA $C = c_1$
(2) AKO $(F = f_3) \vee (B = b_3)$ ONDA $C = c_2$
(3) AKO $(E = e_1) \vee (B = b_1)$ ONDA $(A = a_1) \wedge (D = d_2)$
(4) AKO $F = f_1$ ONDA $D = d_2$
(5) AKO $F = f_2$ ONDA $E = e_2$
(6) AKO $(B = b_3) \vee (D = d_1)$ ONDA $(E = e_1) \wedge (A = a_2)$

Sustav koristimo za izvođenje vrijednosti varijable C ulančavanjem unazad. Prednost imaju pravila s manjim rednim brojem. Pravila koja su jednom palila više ne mogu paliti. Jednom izvedeni međuciljevi brišu se sa stoga, neovisno o njihovoj poziciji na stogu. Na moguće upite od strane sustava, korisnik odgovara sa $B = b_3$ i $F = f_1$. **Što radi ekspertni sustav pri izvođenju vrijednosti varijable C?**

- A Pali četiri pravila i izvodi $C = c_1$
- C Završava s tri činjenice u radnoj memoriji
- B Odbacuje pravilo 6 te kasnije pali pravilo 3
- D Odbacuje pravilo 5 te kasnije pali pravilo 6

10 (T) Semantika operatora negacije u Prologu (operator `not`) temelji se na pretpostavci zatvorenog svijeta. **Što ta pretpostavka znači?**

- A Baza znanja sadrži konačan broj činjenica
- C Dokazane činjenice ne mogu se opovrgnuti
- B Sve dedukcije su logičke posljedice
- D Sve što ne slijedi iz baze znanja je lažno

4. Modeliranje neizvjesnosti (2 pitanja)

11 (T) Bayesovo pravilo čini temelj vjerojatnosnog modeliranja neizvjesnog znanja. **Koju vjerojatnost modelira Bayesovo pravilo, i kako?**

- A Vjerojatnost hipoteze prije predočavanja dokaza na temelju (1) vjerojatnosti hipoteze uz predočen dokaz i (2) združene vjerojatnosti dokaza i hipoteze
- B Združenu vjerojatnost hipoteze i dokaza na temelju (1) uvjetne vjerojatnosti dokaza u predočenu hipotezu i (2) vjerojatnosti dokaza neovisno o hipotezi
- C Uvjetnu vjerojatnost dokaza uz predočenu hipotezu na temelju (1) vjerojatnosti hipoteze prije predočavanja dokaza i (2) vjerojatnosti dokaza neovisno o hipotezi
- D Uvjetnu vjerojatnost hipoteze uz predočen dokaz na temelju (1) uvjetne vjerojatnost dokaza uz predočenu hipotezu i (2) vjerojatnosti hipoteze prije predočavanja dokaza

12 (P) Razmotrimo jezičnu varijablu *starost kanarinca*, definiranu s izrazima *mlad* i *star*. Značenje tih izraza modeliramo neizrazitim skupovima M odnosno S, definiranima nad univerzalnim skupom $\mathbb{R}^+$, koji odgovara godinama. Funkcije pripadnosti μ_M i μ_S definiramo kao po dijelovima linearne funkcije. Funkcija $\mu_M(x)$ ima vrijednost 1 za $0 \leq x \leq 5$, vrijednost 0 za $x \geq 9$, te linearno pada za $5 < x < 9$. Funkcija $\mu_S(x)$ ima vrijednost 0 za $0 \leq x \leq 6$, vrijednost 1 za $x \geq 12$, te linearno raste za $6 < x < 12$. Uporabom Zadehovih operatora definiramo dva neizrazita skupa: skup X_1 sa značenjem *mlad ili star kanarinac* te skup X_2 sa značenjem *mlad ili ne mlad kanarinac*. **Za koje se sve elemente $x \in \mathbb{R}^+$ pripadnost ovim dvama neizrazitim skupovima razlikuje?**

A $5 \leq x \leq 6$ B $7 \leq x \leq 12$ C $9 \leq x \leq 12$ D $7 \leq x \leq 9$

5. Strojno učenje, umjetne neuronske mreže i podržano učenje (5 pitanja)

13 (T) Algoritam propagacije pogreške unazad (engl. *backpropagation algorithm*) rješava problem dodjele odgovornosti pojedinih neurona mreže. Preciznije, algoritam definira kako izračunati pogrešku $\delta_i^{(k)}$ neurona i u sloju k, gdje je k bilo koji skriveni sloj mreže. **O čemu ovisi pogreška $\delta_i^{(k)}$?**

- A O izlazima svih neurona u slojevima $k-1$ (sloj bliže ulazu) čiji su izlazi povezani s ulazom neurona i
- B O pogreškama svih neurona u sloju $k+1$ (sloj bliže izlazu) čiji su ulazi povezani s izlazom neurona i
- C O pogreškama svih neurona u sloju k čiji su izlazi izravno ili neizravno povezani s neuronima izlaznog sloja
- D O razlici ostvarnog i ciljanog izlaza, $t_j - o_j$, za sve neurone j u skrivenom sloju $k-1$ (sloj bliže ulazu)

14 (R) Treniramo naivan Bayesov klasifikator za *"Skupo ljetovanje na Jadranu"*. Skup za učenje je sljedeći:

i	Mjesto	Otok	Smještaj	Prijevoz	y	i	Mjesto	Otok	Smještaj	Prijevoz	y
1	Kvarner	da	privatni	auto	1	5	Kvarner	ne	kamp	bus	0
2	Dalmacija	da	hotel	avion	1	6	Dalmacija	ne	privatni	avion	0
3	Istra	da	kamp	auto	0	7	Istra	ne	kamp	bus	1
4	Dalmacija	da	hotel	auto	1						

Procjene radimo Laplaceovim procjeniteljem "dodaj jedan". Klasificiramo primjer $\mathbf{x} = (\text{Dalmacija}, \text{ne}, \text{kamp}, \text{bus})$. **Koliko iznosi aposteriorna vjerojatnost $P(y = 1|\mathbf{x})$?**

A 0.685 B 0.318 C 0.706 D 0.237

15 (R) Skup primjera za učenje $\{(x_2, x_1, y)\}$ je $\big\{(1,1,-1), (2,4,1), (1,2,-1), (3,3,1), (2,1,-1), (4,2,1)\big\}$. Učenje se provodi uporabom perceptrona TLU s izlaznim vrijednostima -1 i 1 te stopom učenja $\eta = 1$. Početne vrijednosti težinskih faktora su $(w_2, w_1, w_0) = (1.3, -1.2, -10)$. Provedite postupak učenja Rosenblattovim algoritmom. **Koliko se puta tijekom učenja provode korekcije težina te koje su njihove konačne vrijednosti?**

A 4 puta, $(1.3, -2.5, 12)$ B 2 puta, $(-1.1, 0.8, -6.9)$ C Postupak ne konvergira D 2 puta, $(3.3, 2.8, -10)$

16 (P) Radimo svoju implementaciju algoritma ID3. Kako bismo spriječili da se model prenauči, implementirali smo i podrezivanje stabla na dubini k. Nažalost, kod implementacije funkcije informacijske dobiti (IG) potkrala nam se mala pogreška: zaboravili smo negirati vrijednost pri izračunu entropije $E(D)$ skupa primjera D. Dakle, umjesto da izračunava $E(D)$, naša implementacija izračunava $-E(D)$. Neka je M_1^k stablo odluke koje dobivamo učenjem takvim pogrešno implementiranim algoritmom ID3, podrezano na neku konačnu dubinu k. Neka je M_2^k stablo koje bismo dobili da smo algoritam ID3 implementirali ispravno i naučeno stablo podrezali na neku konačnu dubinu k. Ako $k = \infty$, onda to znači da stablo ne podrezujemo. Neka je $E_u(M)$ pogreška učenja modela M, a $E_p(M)$ pogreška modela M na skupu za provjeru. **Što od sljedećeg možemo očekivati da vrijedi?**

A $E_p(M_2^\infty) = E_u(M_2^\infty)$ B $E_p(M_2^\infty) < E_u(M_2^\infty)$ C $E_u(M_1^\infty) = E_u(M_2^\infty)$ D $E_u(M_2^k) < E_u(M_2^\infty)$

17 (P) Rešetkasti svijet sastoji se od četiri ćelije, označene brojevima 1 do 4 i poredane vodoravno slijeva nadesno. Ćelija 4 je terminalna i agentu donosi 1 bod; nema drugih bodova. Svijet je okružen zidovima. Agent može poduzeti akcije *lijevo* i *desno*. Ako bi ga akcija dovela na zid, ostaje u ćeliji u kojoj je bio. Agent uvijek kreće iz ćelije 1. Provodimo postupak Q-učenja. Početni iznosi Q-funkcije su 0. Parametri su $\alpha = 0.5$ i $\gamma = 1$. Agent najprije igra tri epizode u kojima uvijek bira akciju *desno* i uči. Nakon toga igra još 10 epizoda u kojima u svakoj ćeliji pohlepno odabire potez koji mu se čini optimalan i također uči. **Nakon provedenih svih 13 epizoda, koja je očekivana vrijednost** $q(3, desno)$**?**

A Između 0.75 i 0.9995 B Veća od 0.9995 C Manja od 0.75 D Nije moguće odgovoriti

6. Prirodom inspirirani optimizacijski algoritmi (3 pitanja)

18 (R) Generacijskim genetskim algoritmom tražimo maksimum funkcije $f(x, y) = 18 - (x - 4)^2 - (y - 2)^2$. Kao reprezentaciju rješenja koristimo 6-bitovni kromosom, pri čemu se prva tri bita koriste za kodiranje vrijednosti varijable x, a preostala tri bita za kodiranje vrijednosti varijable y. Domena nad kojom se pretražuju vrijednosti od x je $[2, 9]$ te od y je $[-2, 5]$. Populacija se sastoji od četiri jedinke: J1=000110, J2=011001, J3=100111, J4=001110. Pretpostavite da se roditelji biraju proporcionalnom selekcijom te da su u jednom koraku kao roditelji izvučena dva rješenja koja imaju najmanju vjerojatnost odabira. Provedite nad njima postupak križanja s jednom točkom prijeloma (točka prijeloma je nakon prva dva bita); pretpostavite da u ovom koraku operator mutacije svaki puta djeluje na posljednja dva bita kromosoma. **Odredite iznos funkcije f u rješenju koje odgovara djetetu koje će biti poslano u sljedeću generaciju.** (Ako ih operatori križanja i mutacije generiraju više, u novu generaciju treba proslijediti najbolje.)

A 5 B 16 C 9 D 18

19 (P) Ako kod algoritma Ant System postavimo parametre $\alpha = 0$ i $\beta = 1$, **što će biti posljedica?**

A Vjerojatnost odabira nekog brida neće ovisiti o feromonskim tragovima

B U algoritmu se neće događati isparavanje feromonskih tragova

C Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo heurističkoj informaciji

D Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo količini feromonskih tragova

20 (T) Genetički algoritmi oponašaju proces biološke evolucije te implementiraju operatore selekcije, križanja i mutacije. Neka je P populacija kromosoma te neka je $\mathcal{P}$ skup svih populacija. Neka operatori selekcije, križanja i mutacije odgovaraju funkcijama s, k, odnosno m. **Kako možemo formalno opisati preslikavanja koja obavljaju te funkcije?**

A $s : \mathcal{P} \to P$, $k : P \times P \to P$, $m : P \to P \times P$

B $s : \mathcal{P} \to P \times P \times P$, $k : P \times P \to \mathcal{P}$, $m : P \times P \to P$

C $s : \mathcal{P} \to P \times P$, $k : P \times P \to P \times P$, $m : P \to P$

D $s : P \to \mathcal{P}$, $k : P \times P \to P$, $m : P \times P \to \mathcal{P}$

Uvod u umjetnu inteligenciju – pismeni ispit (2021./2022.)

– NEKORIGIRANA VERZIJA –

*Ispit se sastoji od **20 pitanja** i ukupno nosi **20 bodova**. Točan odgovor nosi 1 bod a netočan -1/3 boda. Trajanje ispita je **150 minuta**. Primjerak ispita trebate predati zajedno sa svojim rješenjima.*

1. Pretraživanje prostora stanja i igranje igara (4 pitanja)

1 (R) Neka su definirani skup stanja $S = \{a, b, c, d, e, f\}$ i funkcija sljedbenika $succ(a) = \{(b, 1), (c, 2)\}$, $succ(b) = succ(f) = \emptyset$, $succ(c) = \{(d, 3), (e, 5)\}$, $succ(d) = \{(b, 8), (f, 5)\}$, te $succ(e) = \{(d, 1), (f, 2)\}$. Heurističke vrijednosti čvorova neka su $h(a) = 7$, $h(b) = 4$, $h(c) = 6$, $h(d) = h(e) = 2$, $h(f) = 0$. Početno stanje neka je a, a ciljno f. Izvršite pretraživanje algoritmom A^*, bilježeći pritom sadržaje liste otvorenih čvorova O i zatvorenih čvorova C u svakom koraku algoritma (u nultom koraku $O = [(a, 0)]$ i $C = \emptyset$). **Koji su sadržaji listi O i C nakon petog koraka izvođenja algoritma A^*?**

A Algoritam ne dostiže peti korak

B $O = [(e, 7), (f, 10)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5)\}$

C $O = [(f, 9)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5), (e, 7)\}$

D $O = [(f, 0), (e, 2), (b, 4)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5)\}$

2 (R) Razmatramo igru za dva igrača sa sumom nula. Svako stanje $s \in S$ te igre može se sažeto opisati troznamenkastim prirodnim brojem između 111 i 999. Sljedbenička stanja od s jesu sva ona stanja koja se dobivaju iz s tako da se jedna znamenka poveća za jedan, npr., $succ(235) = \{335, 245, 236\}$. Međutim, stanja koja sadrže znamenku 9 su završna stanja i ona nemaju sljedbeničkih stanja, npr., $succ(932) = \emptyset$. U završnim stanjima, isplata za prvog igrača (MAX) jednaka je razlici prve i treće znamenke, npr., $utility(932) = 9 - 2 = 7$. Isplata za drugog igrača (MIN) je negativna vrijednost isplate za prvog igrača. U igri se natječu dva algoritma minimax, A_1 (igrač MAX) i A_2 (igrač MIN). Oba algoritma pretražuju do dva poteza unaprijed, tj. dubinsko ograničenje algoritma minimax jednako je 2. Međutim, algoritmi koriste različite heuristike. Heuristika h_1 algoritma A_1 jednaka je prvoj znamenci iz s, a heuristika h_2 algorithma A_2 (definirana iz perspektive tog algoritma) jednaka je trećoj znamenci iz s. Npr., $h_1(236) = 2$ i $h_2(236) = 6$ (kod izračuna minimax vrijednosti u stablu sa MAX korijenom vrijednost heuristike h_2 trebate negirati). Početno stanje igre neka je $s_0 = 175$. Prvi potez vuče algoritam A_1 (igrač MAX). **Koji je slijed stanja igre, ako oba igrača vuku svoje minimax-optimalne poteze?**

A $175 \to 176 \to 186$ B $175 \to 275 \to 276$ C $175 \to 176 \to 276$ D $175 \to 275 \to 375$

3 (P) Poželjno svojstvo aloritma pretraživanja jest da je optimalan. Međutim, algoritmi "najbolji prvi" i "uspon na vrh" nisu optimalni. Oba su ova algoritma "pohlepna", ali je algoritam "najbolji prvi" manje pohlepan od algoritma "uspon na vrh", pa u praksi postoji veća vjerojatnost da će algoritam "najboji prvi" pronaći optimalan put. Skicirajte prostor stanja $S = \{a, b, c, d, e, f\}$ s prijelazima $succ(a) = \{b, c\}$, $succ(b) = \{d, e\}$, $succ(c) = succ(d) = succ(e) = \{f\}$. Cijene svih prijelaza su jednake i iznose 1. Heuristika neka je $h(c) = 2$, $h(d) = h(e) = 3$ i $h(f) = 0$. Stanje a je početno stanje, a stanje f je ciljno stanje. **Za koju vrijednost heuristike za stanje b** algoritam "uspona na vrh" *ne* pronalazi optimalno rješenje, ali ga algoritam "najbolji prvi" pronalazi?

A $h(b) = 3$ B $h(b) = 5$ C $h(b) = 1$ D $h(b) = 4$

4 (T) Složenost problema pretraživanja prostora stanja opisali smo parametrima $|S|$, b, d i m. O tim parametrima ovisi kako će se neki algoritam pretraživanja ponašati na dotičnom problemu. Neka je k konačan prirodan broj. **U kojem slučaju će nepotpun algoritam sigurno terminirati (završiti s izvođenjem)?**

A $b \le m \cdot k$ B $d = |S| + k$ C $b < k \cdot |S|$ D $m = d + k$

2. Prikazivanje znanja i automatsko zaključivanje (4 pitanja)

5 (T) Kod prikazivanja znanja formalnom logikom postoji kompromis između ekspresivnosti i odlučivosti sustava logike. **Što to točno znači?**

A Logički sustav koji može vrlo detaljno opisati stvarni svijet ne može izvesti mnoge logičke posljedice

B U logičkom sustavu s potpunim skupom pravila zaključivanja neke logičke posljedice ne možemo dokazati

C Što je u logičkom sustavu veći skup epistemičkih pretpostavki, to je manji skup ontoloških pretpostavki

D Uključivanjem varijabli logički sustav može opisati relacije između objekata, ali postaje nepotpun

6 (R) Želimo dokazati sljedeću relaciju deduktivne posljedice:

$$\forall x\Big(P(x,a) \rightarrow \neg\forall y\big(Q(y) \rightarrow \exists z R(z,y)\big)\Big),\ \forall x \exists y\Big(Q(y) \rightarrow R(y,x)\Big)\ \vdash\ \exists x \neg P(c,x).$$

Pretvorite premise i negaciju ciljne formule u klauzalni oblik te primijenite rezoluciju opovrgavanjem uz strategiju skupa potpore (SoS). **Koliko klauzula ulazi u postupak te je li cilj dokaziv i u koliko rezolucijskih koraka?**

A 4 klauzule; dokazivo u 3 koraka

B 4 klauzule; nije dokazivo

C 4 klauzule; dokazivo u 2 koraka

D 5 klauzula; dokazivo u 4 koraka

7 (P) Neka $F \equiv P \wedge \Big((P \rightarrow S) \wedge (S \rightarrow U)\Big)$ i $G \equiv F \wedge \neg S$. **Što od sljedećeg vrijedi za formule F i G?**

A G je zadovoljiva (konzistentna), a F nije

B Obje formule su kontradikcije

C F je tautologija, a G nije

D F je zadovoljiva (konzistentna), a G nije

8 (T) Postupak rezolucije u logici prvog reda (FOL) oslanja se na algoritam najopćenitijeg zajedničkog unifikatora (MGU). **Što je rezultat algoritma MGU, u slučaju kada se dva izraza mogu unificirati?**

A Formula FOL u obliku disjunkcije konjunkcija

B Rezolventa ili prazna (nil) klauzula

C Skup parova izraza i varijabli FOL

D Neprazan skup atoma i varijabli FOL

3. Logičko programiranje i ekspertni sustavi (2 pitanja)

9 (R) Baza znanja ekspertnog sustava sadrži sljedeća pravila:

(1) AKO $(A = a_2) \wedge (D = d_2)$ ONDA $C = c_1$
(2) AKO $(F = f_3) \vee (B = b_3)$ ONDA $C = c_2$
(3) AKO $(E = e_1) \vee (B = b_1)$ ONDA $(A = a_1) \wedge (D = d_2)$
(4) AKO $F = f_1$ ONDA $D = d_2$
(5) AKO $F = f_2$ ONDA $E = e_2$
(6) AKO $(B = b_3) \vee (D = d_1)$ ONDA $(E = e_1) \wedge (A = a_2)$

Sustav koristimo za izvođenje vrijednosti varijable C ulančavanjem unazad. Prednost imaju pravila s manjim rednim brojem. Pravila koja su jednom palila više ne mogu paliti. Jednom izvedeni međuciljevi brišu se sa stoga, neovisno o njihovoj poziciji na stogu. Na moguće upite od strane sustava, korisnik odgovara sa $B = b_3$ i $F = f_1$. **Što radi ekspertni sustav pri izvođenju vrijednosti varijable C?**

A Odbacuje pravilo 5 te kasnije pali pravilo 6

B Pali pet pravila i izvodi $C = c_1$

C Pali četiri pravila i izvodi $C = c_1$

D Odbacuje pravilo 3 te kasnije pali pravilo 4

10 (T) Semantika operatora negacije u Prologu (operator `not`) temelji se na pretpostavci zatvorenog svijeta. **Što ta pretpostavka znači?**

A Sve dedukcije su logičke posljedice

B Sve što ne slijedi iz baze znanja je lažno

C Baza sadržava isključivo temeljne atome

D Dokazane činjenice ne mogu se opovrgnuti

4. Modeliranje neizvjesnosti (2 pitanja)

11 (P) Razmotrimo jezičnu varijablu *starost kanarinca*, definiranu s izrazima *mlad* i *star*. Značenje tih izraza modeliramo neizrazitim skupovima M odnosno S, definiranima nad univerzalnim skupom $\mathbb{R}^+$, koji odgovara godinama. Funkcije pripadnosti μ_M i μ_S definiramo kao po dijelovima linearne funkcije. Funkcija $\mu_M(x)$ ima vrijednost 1 za $0 \leq x \leq 5$, vrijednost 0 za $x \geq 9$, te linearno pada za $5 < x < 9$. Funkcija $\mu_S(x)$ ima vrijednost 0 za $0 \leq x \leq 6$, vrijednost 1 za $x \geq 12$, te linearno raste za $6 < x < 12$. Uporabom Zadehovih operatora definiramo dva neizrazita skupa: skup X_1 sa značenjem *mlad ili star kanarinac* te skup X_2 sa značenjem *mlad ili ne mlad kanarinac*. **Za koje se sve elemente $x \in \mathbb{R}^+$ pripadnost ovim dvama neizrazitim skupovima razlikuje?**

A $5 \leq x \leq 6$ B $7 \leq x \leq 12$ C $7 \leq x \leq 9$ D $9 \leq x \leq 12$

12 (T) Bayesovo pravilo čini temelj vjerojatnosnog modeliranja neizvjesnog znanja. **Koju vjerojatnost modelira Bayesovo pravilo, i kako?**

A Uvjetnu vjerojatnost hipoteze uz predočen dokaz na temelju (1) uvjetne vjerojatnost dokaza uz predočenu hipotezu i (2) vjerojatnosti hipoteze prije predočavanja dokaza

B Združenu vjerojatnost hipoteze i dokaza na temelju (1) uvjetne vjerojatnosti dokaza u predočenu hipotezu i (2) vjerojatnosti dokaza neovisno o hipotezi

C Uvjetnu vjerojatnost dokaza uz predočenu hipotezu na temelju (1) vjerojatnosti hipoteze prije predočavanja dokaza i (2) vjerojatnosti dokaza neovisno o hipotezi

D Vjerojatnost hipoteze prije predočavanja dokaza na temelju (1) vjerojatnosti hipoteze uz predočen dokaz i (2) združene vjerojatnosti dokaza i hipoteze

5. Strojno učenje, umjetne neuronske mreže i podržano učenje (5 pitanja)

13 (R) Treniramo naivan Bayesov klasifikator za *"Skupo ljetovanje na Jadranu"*. Skup za učenje je sljedeći:

i	Mjesto	Otok	Smještaj	Prijevoz	y	i	Mjesto	Otok	Smještaj	Prijevoz	y
1	Kvarner	da	privatni	auto	1	5	Kvarner	ne	kamp	bus	0
2	Dalmacija	da	hotel	avion	1	6	Dalmacija	ne	privatni	avion	0
3	Istra	da	kamp	auto	0	7	Istra	ne	kamp	bus	1
4	Dalmacija	da	hotel	auto	1						

Procjene radimo Laplaceovim procjeniteljem "dodaj jedan". Klasificiramo primjer $\mathbf{x} = (\text{Dalmacija}, \text{ne}, \text{kamp}, \text{bus})$. **Koliko iznosi aposteriorna vjerojatnost $P(y = 1|\mathbf{x})$?**

A 0.237 B 0.318 C 0.706 D 0.685

14 (P) Radimo svoju implementaciju algoritma ID3. Kako bismo spriječili da se model prenauči, implementirali smo i podrezivanje stabla na dubini k. Nažalost, kod implementacije funkcije informacijske dobiti (IG) potkrala nam se mala pogreška: zaboravili smo negirati vrijednost pri izračunu entropije $E(D)$ skupa primjera D. Dakle, umjesto da izračunava $E(D)$, naša implementacija izračunava $-E(D)$. Neka je M_1^k stablo odluke koje dobivamo učenjem takvim pogrešno implementiranim algoritmom ID3, podrezano na neku konačnu dubinu k. Neka je M_2^k stablo koje bismo dobili da smo algoritam ID3 implementirali ispravno i naučeno stablo podrezali na neku konačnu dubinu k. Ako $k = \infty$, onda to znači da stablo ne podrezujemo. Neka je $E_u(M)$ pogreška učenja modela M, a $E_p(M)$ pogreška modela M na skupu za provjeru. **Što od sljedećeg možemo očekivati da vrijedi?**

A $E_p(M_1^k) > E_p(M_2^k)$ B $E_p(M_1^k) < E_u(M_1^k)$ C $E_p(M_1^k) = E_u(M_1^k)$ D $E_p(M_1^\infty) < E_u(M_1^\infty)$

15 (R) Skup primjera za učenje $\{(x_2, x_1, y)\}$ je $\{(1,1,-1), (2,4,1), (1,2,-1), (3,3,1), (2,1,-1), (4,2,1)\}$. Učenje se provodi uporabom perceptrona TLU s izlaznim vrijednostima -1 i 1 te stopom učenja $\eta = 1$. Početne vrijednosti težinskih faktora su $(w_2, w_1, w_0) = (1.3, -1.2, -10)$. Provedite postupak učenja Rosenblattovim algoritmom. **Koliko se puta tijekom učenja provode korekcije težina te koje su njihove konačne vrijednosti?**

A 2 puta, $(-1.1, 0.8, -6.9)$ B 2 puta, $(3.3, 2.8, -10)$ C 4 puta, $(1.3, -2.5, 12)$ D 3 puta, $(1.3, 1.2, -5.2)$

16 (T) Algoritam propagacije pogreške unazad (engl. *backpropagation algorithm*) rješava problem dodjele odgovornosti pojedinih neurona mreže. Preciznije, algoritam definira kako izračunati pogrešku $\delta_i^{(k)}$ neurona i u sloju k, gdje je k bilo koji skriveni sloj mreže. **O čemu ovisi pogreška $\delta_i^{(k)}$?**

- A O izlazima svih neurona u slojevima $k-1$ (sloj bliže ulazu) čiji su izlazi povezani s ulazom neurona i
- B O pogreškama svih neurona u sloju $k+1$ (sloj bliže izlazu) čiji su ulazi povezani s izlazom neurona i
- C O razlici ostvarnog i ciljanog izlaza, $t_j - o_j$, za sve neurone j u skrivenom sloju $k-1$ (sloj bliže ulazu)
- D O pogreškama svih neurona u sloju k čiji su izlazi izravno ili neizravno povezani s neuronima izlaznog sloja

17 (P) Rešetkasti svijet sastoji se od četiri ćelije, označene brojevima 1 do 4 i poredane vodoravno slijeva nadesno. Ćelija 4 je terminalna i agentu donosi 1 bod; nema drugih bodova. Svijet je okružen zidovima. Agent može poduzeti akcije *lijevo* i *desno*. Ako bi ga akcija dovela na zid, ostaje u ćeliji u kojoj je bio. Agent uvijek kreće iz ćelije 1. Provodimo postupak Q-učenja. Početni iznosi Q-funkcije su 0. Parametri su $\alpha = 0.5$ i $\gamma = 1$. Agent najprije igra tri epizode u kojima uvijek bira akciju *desno* i uči. Nakon toga igra još 10 epizoda u kojima u svakoj ćeliji pohlepno odabire potez koji mu se čini optimalan i također uči. **Nakon provedenih svih 13 epizoda, koja je očekivana vrijednost $q(3, \mathit{desno})$?**

A Manja od 0.75 B Veća od 0.9995 C Između 0.75 i 0.9995 D Nije moguće odgovoriti

6. Prirodom inspirirani optimizacijski algoritmi (3 pitanja)

18 (P) Ako kod algoritma Ant System postavimo parametre $\alpha = 0$ i $\beta = 1$, **što će biti posljedica?**

- A Vjerojatnost odabira nekog brida neće ovisiti o feromonskim tragovima
- B Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo heurističkoj informaciji
- C U algoritmu se neće događati isparavanje feromonskih tragova
- D Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo količini feromonskih tragova

19 (T) Genetički algoritmi oponašaju proces biološke evolucije te implementiraju operatore selekcije, križanja i mutacije. Neka je P populacija kromosoma te neka je $\mathcal{P}$ skup svih populacija. Neka operatori selekcije, križanja i mutacije odgovaraju funkcijama s, k, odnosno m. **Kako možemo formalno opisati preslikavanja koja obavljaju te funkcije?**

- A $s : P \to \mathcal{P}$, $k : P \times P \to P$, $m : P \times P \to \mathcal{P}$
- B $s : \mathcal{P} \to P$, $k : P \times P \to P$, $m : P \to P \times P$
- C $s : \mathcal{P} \to P \times P$, $k : P \times P \to P \times P$, $m : P \to P$
- D $s : \mathcal{P} \to P \times P \times P$, $k : P \times P \to \mathcal{P}$, $m : P \times P \to P$

20 (R) Generacijskim genetskim algoritmom tražimo maksimum funkcije $f(x, y) = 18 - (x-4)^2 - (y-2)^2$. Kao reprezentaciju rješenja koristimo 6-bitovni kromosom, pri čemu se prva tri bita koriste za kodiranje vrijednosti varijable x, a preostala tri bita za kodiranje vrijednosti varijable y. Domena nad kojom se pretražuju vrijednosti od x je $[2, 9]$ te od y je $[-2, 5]$. Populacija se sastoji od četiri jedinke: J1=000110, J2=011001, J3=100111, J4=001110. Pretpostavite da se roditelji biraju proporcionalnom selekcijom te da su u jednom koraku kao roditelji izvučena dva rješenja koja imaju najmanju vjerojatnost odabira. Provedite nad njima postupak križanja s jednom točkom prijeloma (točka prijeloma je nakon prva dva bita); pretpostavite da u ovom koraku operator mutacije svaki puta djeluje na posljednja dva bita kromosoma. **Odredite iznos funkcije f u rješenju koje odgovara djetetu koje će biti poslano u sljedeću generaciju.** (Ako ih operatori križanja i mutacije generiraju više, u novu generaciju treba proslijediti najbolje.)

A 16 B 5 C 9 D 18

Uvod u umjetnu inteligenciju – pismeni ispit (2021./2022.)

– NEKORIGIRANA VERZIJA –

*Ispit se sastoji od **20 pitanja** i ukupno nosi **20 bodova**. Točan odgovor nosi 1 bod a netočan -1/3 boda. Trajanje ispita je **150 minuta**. Primjerak ispita trebate predati zajedno sa svojim rješenjima.*

1. Pretraživanje prostora stanja i igranje igara (4 pitanja)

1 (R) Neka su definirani skup stanja $S = \{a, b, c, d, e, f\}$ i funkcija sljedbenika $succ(a) = \{(b, 1), (c, 2)\}$, $succ(b) = succ(f) = \emptyset$, $succ(c) = \{(d, 3), (e, 5)\}$, $succ(d) = \{(b, 8), (f, 5)\}$, te $succ(e) = \{(d, 1), (f, 2)\}$. Heurističke vrijednosti čvorova neka su $h(a) = 7$, $h(b) = 4$, $h(c) = 6$, $h(d) = h(e) = 2$, $h(f) = 0$. Početno stanje neka je a, a ciljno f. Izvršite pretraživanje algoritmom A^*, bilježeći pritom sadržaje liste otvorenih čvorova O i zatvorenih čvorova C u svakom koraku algoritma (u nultom koraku $O = [(a, 0)]$ i $C = \emptyset$). **Koji su sadržaji listi O i C nakon četvrtog koraka izvođenja algoritma A^*?**

A $O = [(f, 10)],\ \ C = \{(a, 0), (b, 1), (c, 2), (d, 5), (e, 7)\}$

B $O = [(e, 7), (f, 10), (b, 13)],\ \ C = \{(a, 0), (b, 1), (c, 2), (d, 5)\}$

C $O = [(e, 7), (f, 10)],\ \ C = \{(a, 0), (b, 1), (c, 2), (d, 5)\}$

D Algoritam ne dostiže četvrti korak

2 (R) Razmatramo igru za dva igrača sa sumom nula. Svako stanje $s \in S$ te igre može se sažeto opisati troznamenkastim prirodnim brojem između 111 i 999. Sljedbenička stanja od s jesu sva ona stanja koja se dobivaju iz s tako da se jedna znamenka poveća za jedan, npr., $succ(235) = \{335, 245, 236\}$. Međutim, stanja koja sadrže znamenku 9 su završna stanja i ona nemaju sljedbeničkih stanja, npr., $succ(932) = \emptyset$. U završnim stanjima, isplata za prvog igrača (MAX) jednaka je razlici prve i treće znamenke, npr., $utility(932) = 9 - 2 = 7$. Isplata za drugog igrača (MIN) je negativna vrijednost isplate za prvog igrača. U igri se natječu dva algoritma minimax, A_1 (igrač MAX) i A_2 (igrač MIN). Oba algoritma pretražuju do dva poteza unaprijed, tj. dubinsko ograničenje algoritma minimax jednako je 2. Međutim, algoritmi koriste različite heuristike. Heuristika h_1 algoritma A_1 jednaka je prvoj znamenci iz s, a heuristika h_2 algorithma A_2 (definirana iz perspektive tog algoritma) jednaka je trećoj znamenci iz s. Npr., $h_1(236) = 2$ i $h_2(236) = 6$ (kod izračuna minimax vrijednosti u stablu sa MAX korijenom vrijednost heuristike h_2 trebate negirati). Početno stanje igre neka je $s_0 = 175$. Prvi potez vuče algoritam A_1 (igrač MAX). **Koji je slijed stanja igre, ako oba igrača vuku svoje minimax-optimalne poteze?**

A $175 \to 176 \to 276$ B $175 \to 176 \to 186$ C $175 \to 275 \to 276$ D $175 \to 275 \to 375$

3 (T) Složenost problema pretraživanja prostora stanja opisali smo parametrima $|S|$, b, d i m. O tim parametrima ovisi kako će se neki algoritam pretraživanja ponašati na dotičnom problemu. Neka je k konačan prirodan broj. **U kojem slučaju će nepotpun algoritam sigurno terminirati (završiti s izvođenjem)?**

A $d = |S| + k$ B $m = d + k$ C $b \leq m \cdot k$ D $b < k \cdot |S|$

4 (P) Poželjno svojstvo aloritma pretraživanja jest da je optimalan. Međutim, algoritmi "najbolji prvi" i "uspon na vrh" nisu optimalni. Oba su ova algoritma "pohlepna", ali je algoritam "najbolji prvi" manje pohlepan od algoritma "uspon na vrh", pa u praksi postoji veća vjerojatnost da će algoritam "najboji prvi" pronaći optimalan put. Skicirajte prostor stanja $S = \{a, b, c, d, e, f\}$ s prijelazima $succ(a) = \{b, c\}$, $succ(b) = \{d, e\}$, $succ(c) = succ(d) = succ(e) = \{f\}$. Cijene svih prijelaza su jednake i iznose 1. Heuristika neka je $h(c) = 2$, $h(d) = h(e) = 3$ i $h(f) = 0$. Stanje a je početno stanje, a stanje f je ciljno stanje. **Za koju vrijednost heuristike za stanje b** algoritam "uspona na vrh" *ne* pronalazi optimalno rješenje, ali ga algoritam "najbolji prvi" pronalazi?

A $h(b) = 3$ B $h(b) = 5$ C $h(b) = 4$ D $h(b) = 1$

2. Prikazivanje znanja i automatsko zaključivanje (4 pitanja)

5 (P) Neka $F \equiv P \land \Big((P \to S) \land (S \to U)\Big)$ i $G \equiv F \land \neg S$. **Što od sljedećeg vrijedi za formule F i G?**

- A Obje formule su tautologije
- B F je zadovoljiva (konzistentna), a G nije
- C G je zadovoljiva (konzistentna), a F nije
- D Obje formule su kontradikcije

6 (R) Želimo dokazati sljedeću relaciju deduktivne posljedice:

$$\forall x\Big(P(x,a) \to \neg\forall y\big(Q(y) \to \exists z R(z,y)\big)\Big),\ \exists x\forall y\Big(Q(y) \to R(x,y)\Big)\ \vdash\ \exists x\neg\Big(P(c,x) \land R(x,c)\Big).$$

Pretvorite premise i negaciju ciljne formule u klauzalni oblik te primijenite rezoluciju opovrgavanjem uz strategiju skupa potpore (SoS). **Koliko klauzula ulazi u postupak te je li cilj dokaziv i u koliko rezolucijskih koraka?**

- A 4 klauzule; dokazivo u 4 koraka
- B 5 klauzula; dokazivo u 3 koraka
- C 5 klauzula; dokazivo u 4 koraka
- D 3 klauzule; dokazivo u 2 koraka

7 (T) Postupak rezolucije u logici prvog reda (FOL) oslanja se na algoritam najopćenitijeg zajedničkog unifikatora (MGU). **Što je rezultat algoritma MGU, u slučaju kada se dva izraza mogu unificirati?**

- A Rezolventa ili prazna (nil) klauzula
- B Neprazan skup atoma i varijabli FOL
- C Skup parova izraza i varijabli FOL
- D Formula FOL u obliku disjunkcije konjunkcija

8 (T) Kod prikazivanja znanja formalnom logikom postoji kompromis između ekspresivnosti i odlučivosti sustava logike. **Što to točno znači?**

- A Uključivanjem varijabli logički sustav može opisati relacije između objekata, ali postaje nepotpun
- B Logički sustav koji može vrlo detaljno opisati stvarni svijet ne može izvesti mnoge logičke posljedice
- C Što je u logičkom sustavu veći skup epistemičkih pretpostavki, to je manji skup ontoloških pretpostavki
- D U logičkom sustavu s potpunim skupom pravila zaključivanja neke logičke posljedice ne možemo dokazati

3. Logičko programiranje i ekspertni sustavi (2 pitanja)

9 (T) Semantika operatora negacije u Prologu (operator `not`) temelji se na pretpostavci zatvorenog svijeta. **Što ta pretpostavka znači?**

- A Sve dedukcije su logičke posljedice
- B Sve što ne slijedi iz baze znanja je lažno
- C Domena interpretacije je konačna
- D U bazu se ne mogu dodavati nova pravila

10 (R) Baza znanja ekspertnog sustava sadrži sljedeća pravila:

(1) AKO $(A = a_2) \land (D = d_2)$ ONDA $C = c_1$
(2) AKO $(F = f_3) \lor (B = b_3)$ ONDA $C = c_2$
(3) AKO $(E = e_1) \lor (B = b_1)$ ONDA $(A = a_1) \land (D = d_2)$
(4) AKO $F = f_1$ ONDA $D = d_2$
(5) AKO $F = f_2$ ONDA $E = e_2$
(6) AKO $(B = b_3) \lor (D = d_1)$ ONDA $(E = e_1) \land (A = a_2)$

Sustav koristimo za izvođenje vrijednosti varijable C ulančavanjem unazad. Prednost imaju pravila s manjim rednim brojem. Pravila koja su jednom palila više ne mogu paliti. Jednom izvedeni međuciljevi brišu se sa stoga, neovisno o njihovoj poziciji na stogu. Na možebitne upite od strane sustava, korisnik odgovara sa $B = b_3$ i $F = f_1$. **Što radi ekspertni sustav pri izvođenju vrijednosti varijable C?**

- A Pali pet pravila i izvodi $C = c_1$
- B Izvodi $E = e_1$ te kasnije $E = e_2$
- C Odbacuje pravilo 2 te kasnije pali pravilo 5
- D Izvodi $A = a_2$ te kasnije $A = a_1$

4. Modeliranje neizvjesnosti (2 pitanja)

11 (T) Bayesovo pravilo čini temelj vjerojatnosnog modeliranja neizvjesnog znanja. **Koju vjerojatnost modelira Bayesovo pravilo, i kako?**

A Združenu vjerojatnost hipoteze i dokaza na temelju (1) uvjetne vjerojatnosti dokaza u predočenu hipotezu i (2) vjerojatnosti dokaza neovisno o hipotezi

B Uvjetnu vjerojatnost dokaza uz predočenu hipotezu na temelju (1) vjerojatnosti hipoteze prije predočavanja dokaza i (2) vjerojatnosti dokaza neovisno o hipotezi

C Vjerojatnost hipoteze prije predočavanja dokaza na temelju (1) vjerojatnosti hipoteze uz predočen dokaz i (2) združene vjerojatnosti dokaza i hipoteze

D Uvjetnu vjerojatnost hipoteze uz predočen dokaz na temelju (1) uvjetne vjerojatnost dokaza uz predočenu hipotezu i (2) vjerojatnosti hipoteze prije predočavanja dokaza

12 (P) Razmotrimo jezičnu varijablu *starost kanarinca*, definiranu s izrazima *mlad* i *star*. Značenje tih izraza modeliramo neizrazitim skupovima M odnosno S, definiranima nad univerzalnim skupom $\mathbb{R}^+$, koji odgovara godinama. Funkcije pripadnosti μ_M i μ_S definiramo kao po dijelovima linearne funkcije. Funkcija $\mu_M(x)$ ima vrijednost 1 za $0 \leq x \leq 5$, vrijednost 0 za $x \geq 9$, te linearno pada za $5 < x < 9$. Funkcija $\mu_S(x)$ ima vrijednost 0 za $0 \leq x \leq 6$, vrijednost 1 za $x \geq 12$, te linearno raste za $6 < x < 12$. Uporabom Zadehovih operatora definiramo dva neizrazita skupa: skup X_1 sa značenjem *mlad ili star kanarinac* te skup X_2 sa značenjem *mlad ili ne mlad kanarinac*. **Za koje se sve elemente $x \in \mathbb{R}^+$ pripadnost ovim dvama neizrazitim skupovima razlikuje?**

A $9 \leq x \leq 12$ B $7 \leq x \leq 9$ C $5 \leq x \leq 6$ D $7 \leq x \leq 12$

5. Strojno učenje, umjetne neuronske mreže i podržano učenje (5 pitanja)

13 (T) Algoritam propagacije pogreške unazad (engl. *backpropagation algorithm*) rješava problem dodjele odgovornosti pojedinih neurona mreže. Preciznije, algoritam definira kako izračunati pogrešku $\delta_i^{(k)}$ neurona i u sloju k, gdje je k bilo koji skriveni sloj mreže. **O čemu ovisi pogreška $\delta_i^{(k)}$?**

A O pogreškama svih neurona u sloju $k+1$ (sloj bliže izlazu) čiji su ulazi povezani s izlazom neurona i

B O razlici ostvarnog i ciljanog izlaza, $t_j - o_j$, za sve neurone j u skrivenom sloju $k-1$ (sloj bliže ulazu)

C O izlazima svih neurona u slojevima $k-1$ (sloj bliže ulazu) čiji su izlazi povezani s ulazom neurona i

D O pogreškama svih neurona u sloju k čiji su izlazi izravno ili neizravno povezani s neuronima izlaznog sloja

14 (P) Radimo svoju implementaciju algoritma ID3. Kako bismo spriječili da se model prenauči, implementirali smo i podrezivanje stabla na dubini k. Nažalost, kod implementacije funkcije informacijske dobiti (IG) potkrala nam se mala pogreška: zaboravili smo negirati vrijednost pri izračunu entropije $E(D)$ skupa primjera D. Dakle, umjesto da izračunava $E(D)$, naša implementacija izračunava $-E(D)$. Neka je M_1^k stablo odluke koje dobivamo učenjem takvim pogrešno implementiranim algoritmom ID3, podrezano na neku konačnu dubinu k. Neka je M_2^k stablo koje bismo dobili da smo algoritam ID3 implementirali ispravno i naučeno stablo podrezali na neku konačnu dubinu k. Ako $k = \infty$, onda to znači da stablo ne podrezujemo. Neka je $E_u(M)$ pogreška učenja modela M, a $E_p(M)$ pogreška modela M na skupu za provjeru. **Što od sljedećeg možemo očekivati da vrijedi?**

A $E_p(M_2^k) < E_u(M_2^k)$ B $E_p(M_1^\infty) = E_p(M_2^\infty)$ C $E_u(M_2^k) = E_u(M_2^\infty)$ D $E_p(M_1^\infty) > E_p(M_2^\infty)$

15 (R) Treniramo naivan Bayesov klasifikator za *"Skupo ljetovanje na Jadranu"*. Skup za učenje je sljedeći:

i	Mjesto	Otok	Smještaj	Prijevoz	y	i	Mjesto	Otok	Smještaj	Prijevoz	y
1	Kvarner	da	privatni	auto	1	5	Kvarner	ne	kamp	bus	0
2	Dalmacija	da	hotel	avion	1	6	Dalmacija	ne	privatni	avion	0
3	Istra	da	kamp	auto	0	7	Istra	ne	kamp	bus	1
4	Dalmacija	da	hotel	auto	1						

Procjene radimo Laplaceovim procjeniteljem "dodaj jedan". Klasificiramo primjer $\mathbf{x} = (\text{Istra}, \text{ne}, \text{kamp}, \text{bus})$. **Koliko iznosi aposteriorna vjerojatnost $P(y = 1|\mathbf{x})$?**

A 0.318 B 0.685 C 0.237 D 0.706

16 (R) Skup primjera za učenje $\{(x_2, x_1, y)\}$ je $\{(1,1,-1),(2,4,1),(1,2,-1),(3,3,1),(2,1,-1),(4,2,1)\}$. Učenje se provodi uporabom perceptrona TLU s izlaznim vrijednostima -1 i 1 te stopom učenja $\eta = 1$. Početne vrijednosti težinskih faktora su $(w_2, w_1, w_0) = (1.3, -1.2, -10)$. Provedite postupak učenja Rosenblattovim algoritmom. **Koliko se puta tijekom učenja provode korekcije težina te koje su njihove konačne vrijednosti?**

A 3 puta, $(-5.2, 0.7, 1.2)$ B 2 puta, $(3.3, 2.8, -10)$ C 4 puta, $(5.5, -1.5, 10)$ D 3 puta, $(1.3, 1.2, -5.2)$

17 (P) Rešetkasti svijet sastoji se od četiri ćelije, označene brojevima 1 do 4 i poredane vodoravno slijeva nadesno. Ćelija 4 je terminalna i agentu donosi 1 bod; nema drugih bodova. Svijet je okružen zidovima. Agent može poduzeti akcije *lijevo* i *desno*. Ako bi ga akcija dovela na zid, ostaje u ćeliji u kojoj je bio. Agent uvijek kreće iz ćelije 1. Provodimo postupak Q-učenja. Početni iznosi Q-funkcije su 0. Parametri su $\alpha = 0.5$ i $\gamma = 1$. Agent najprije igra tri epizode u kojima uvijek bira akciju *desno* i uči. Nakon toga igra još 10 epizoda u kojima u svakoj ćeliji pohlepno odabire potez koji mu se čini optimalan i također uči. **Nakon provedenih svih 13 epizoda, koja je očekivana vrijednost $q(3, desno)$?**

A Nije moguće odgovoriti B Veća od 0.9995 C Manja od 0.75 D Između 0.75 i 0.9995

6. Prirodom inspirirani optimizacijski algoritmi (3 pitanja)

18 (P) Ako kod algoritma Ant System postavimo parametre $\alpha = 0$ i $\beta = 1$, **što će biti posljedica?**

A U algoritmu se neće događati isparavanje feromonskih tragova

B Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo heurističkoj informaciji

C Vjerojatnost odabira nekog brida neće ovisiti o feromonskim tragovima

D Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo količini feromonskih tragova

19 (R) Generacijskim genetskim algoritmom tražimo maksimum funkcije $f(x, y) = 20 - (x-3)^2 - (y-4)^2$. Kao reprezentaciju rješenja koristimo 6-bitovni kromosom, pri čemu se prva tri bita koriste za kodiranje vrijednosti varijable x, a preostala tri bita za kodiranje vrijednosti varijable y. Domena nad kojom se pretražuju vrijednosti od x je $[1, 8]$ te od y je $[0, 7]$. Populacija se sastoji od četiri jedinke: J1=000110, J2=011001, J3=100111, J4=001110. Pretpostavite da se roditelji biraju proporcionalnom selekcijom te da su u jednom koraku kao roditelji izvučena dva rješenja koja imaju najmanju vjerojatnost odabira. Provedite nad njima postupak križanja s jednom točkom prijeloma (točka prijeloma je nakon prva dva bita); pretpostavite da u ovom koraku operator mutacije svaki puta djeluje na posljednja dva bita kromosoma. **Odredite iznos funkcije f u rješenju koje odgovara djetetu koje će biti poslano u sljedeću generaciju.** (Ako ih operatori križanja i mutacije generiraju više, u novu generaciju treba proslijediti najbolje.)

A 11 B 18 C 20 D 7

20 (T) Genetički algoritmi oponašaju proces biološke evolucije te implementiraju operatore selekcije, križanja i mutacije. Neka je P populacija kromosoma te neka je $\mathcal{P}$ skup svih populacija. Neka operatori selekcije, križanja i mutacije odgovaraju funkcijama s, k, odnosno m. **Kako možemo formalno opisati preslikavanja koja obavljaju te funkcije?**

A $s : \mathcal{P} \to P \times P$, $k : P \times P \to P \times P$, $m : P \to P$

B $s : \mathcal{P} \to P \times P \times P$, $k : P \times P \to \mathcal{P}$, $m : P \times P \to P$

C $s : P \to \mathcal{P}$, $k : P \times P \to P$, $m : P \times P \to \mathcal{P}$

D $s : \mathcal{P} \to P$, $k : P \times P \to P$, $m : P \to P \times P$

Uvod u umjetnu inteligenciju – pismeni ispit (2021./2022.)

– NEKORIGIRANA VERZIJA –

*Ispit se sastoji od **20 pitanja** i ukupno nosi **20 bodova**. Točan odgovor nosi 1 bod a netočan -1/3 boda. Trajanje ispita je **150 minuta**. Primjerak ispita trebate predati zajedno sa svojim rješenjima.*

1. Pretraživanje prostora stanja i igranje igara (4 pitanja)

1 (R) Razmatramo igru za dva igrača sa sumom nula. Svako stanje $s \in S$ te igre može se sažeto opisati troznamenkastim prirodnim brojem između 111 i 999. Sljedbenička stanja od s jesu sva ona stanja koja se dobivaju iz s tako da se jedna znamenka poveća za jedan, npr., $succ(235) = \{335, 245, 236\}$. Međutim, stanja koja sadrže znamenku 9 su završna stanja i ona nemaju sljedbeničkih stanja, npr., $succ(932) = \emptyset$. U završnim stanjima, isplata za prvog igrača (MAX) jednaka je razlici prve i treće znamenke, npr., $utility(932) = 9 - 2 = 7$. Isplata za drugog igrača (MIN) je negativna vrijednost isplate za prvog igrača. U igri se natječu dva algoritma minimax, A_1 (igrač MAX) i A_2 (igrač MIN). Oba algoritma pretražuju do dva poteza unaprijed, tj. dubinsko ograničenje algoritma minimax jednako je 2. Međutim, algoritmi koriste različite heuristike. Heuristika h_1 algoritma A_1 jednaka je prvoj znamenci iz s, a heuristika h_2 algorithma A_2 (definirana iz perspektive tog algoritma) jednaka je trećoj znamenci iz s. Npr., $h_1(236) = 2$ i $h_2(236) = 6$ (kod izračuna minimax vrijednosti u stablu sa MAX korijenom vrijednost heuristike h_2 trebate negirati). Početno stanje igre neka je $s_0 = 175$. Prvi potez vuče algoritam A_1 (igrač MAX). **Koji je slijed stanja igre, ako oba igrača vuku svoje minimax-optimalne poteze?**

A $175 \to 176 \to 276$ B $175 \to 275 \to 375$ C $175 \to 176 \to 186$ D $175 \to 275 \to 276$

2 (T) Složenost problema pretraživanja prostora stanja opisali smo parametrima $|S|$, b, d i m. O tim parametrima ovisi kako će se neki algoritam pretraživanja ponašati na dotičnom problemu. Neka je k konačan prirodan broj. **U kojem slučaju će nepotpun algoritam sigurno terminirati (završiti s izvođenjem)?**

A $m = d + k$ B $d = |S| + k$ C $b \leq m \cdot k$ D $b < k \cdot |S|$

3 (R) Neka su definirani skup stanja $S = \{a, b, c, d, e, f\}$ i funkcija sljedbenika $succ(a) = \{(b, 1), (c, 2)\}$, $succ(b) = succ(f) = \emptyset$, $succ(c) = \{(d, 3), (e, 5)\}$, $succ(d) = \{(b, 8), (f, 5)\}$, te $succ(e) = \{(d, 1), (f, 2)\}$. Heurističke vrijednosti čvorova neka su $h(a) = 7$, $h(b) = 4$, $h(c) = 6$, $h(d) = h(e) = 2$, $h(f) = 0$. Početno stanje neka je a, a ciljno f. Izvršite pretraživanje algoritmom A^*, bilježeći pritom sadržaje liste otvorenih čvorova O i zatvorenih čvorova C u svakom koraku algoritma (u nultom koraku $O = [(a, 0)]$ i $C = \emptyset$). **Koji su sadržaji listi O i C nakon petog koraka izvođenja algoritma A^*?**

A $O = [(e, 7), (f, 10)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5)\}$

B $O = [(f, 9)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5), (e, 7)\}$

C Algoritam ne dostiže peti korak

D $O = [(f, 0), (e, 2), (b, 4)]$, $C = \{(a, 0), (b, 1), (c, 2), (d, 5)\}$

4 (P) Poželjno svojstvo aloritma pretraživanja jest da je optimalan. Međutim, algoritmi "najbolji prvi" i "uspon na vrh" nisu optimalni. Oba su ova algoritma "pohlepna", ali je algoritam "najbolji prvi" manje pohlepan od algoritma "uspon na vrh", pa u praksi postoji veća vjerojatnost da će algoritam "najboji prvi" pronaći optimalan put. Skicirajte prostor stanja $S = \{a, b, c, d, e, f\}$ s prijelazima $succ(a) = \{b, c\}$, $succ(b) = \{d, e\}$, $succ(c) = succ(d) = succ(e) = \{f\}$. Cijene svih prijelaza su jednake i iznose 1. Heuristika neka je $h(b) = 1$, $h(d) = h(e) = 3$ i $h(f) = 0$. Stanje a je početno stanje, a stanje f je ciljno stanje. **Za koju vrijednost heuristike za stanje** c algoritam "uspona na vrh" *ne* pronalazi optimalno rješenje, ali ga algoritam "najbolji prvi" pronalazi?

A $h(c) = 0$ B $h(c) = 2$ C $h(c) = 4$ D $h(c) = 5$

2. Prikazivanje znanja i automatsko zaključivanje (4 pitanja)

5 (T) Postupak rezolucije u logici prvog reda (FOL) oslanja se na algoritam najopćenitijeg zajedničkog unifikatora (MGU). **Što je rezultat algoritma MGU, u slučaju kada se dva izraza mogu unificirati?**

A Skup parova izraza i varijabli FOL
B Formula FOL u obliku disjunkcije konjunkcija
C Neprazan skup atoma i varijabli FOL
D Rezolventa ili prazna (nil) klauzula

6 (R) Želimo dokazati sljedeću relaciju deduktivne posljedice:

$$\forall x\Big(P(x,a) \to \neg\forall y\big(Q(y) \to \exists z R(z,y)\big)\Big),\ \forall x\exists y\Big(Q(y) \to R(y,x)\Big)\ \vdash\ \exists x\neg\Big(P(c,x) \land R(x,c)\Big).$$

Pretvorite premise i negaciju ciljne formule u klauzalni oblik te primijenite rezoluciju opovrgavanjem uz strategiju skupa potpore (SoS). **Koliko klauzula ulazi u postupak te je li cilj dokaziv i u koliko rezolucijskih koraka?**

A 5 klauzula; nije dokazivo
B 4 klauzule; dokazivo u 2 koraka
C 4 klauzule; nije dokazivo
D 5 klauzula; dokazivo u 5 koraka

7 (P) Neka $F \equiv P \land \Big((P \to S) \land (S \to U)\Big)$ i $G \equiv F \land \neg S$. **Što od sljedećeg vrijedi za formule F i G?**

A G je zadovoljiva (konzistentna), a F nije
B Obje formule su tautologije
C F je zadovoljiva (konzistentna), a G nije
D G je tautologija, a F nije

8 (T) Kod prikazivanja znanja formalnom logikom postoji kompromis između ekspresivnosti i odlučivosti sustava logike. **Što to točno znači?**

A Logički sustav koji može vrlo detaljno opisati stvarni svijet ne može izvesti mnoge logičke posljedice
B U logičkom sustavu s potpunim skupom pravila zaključivanja neke logičke posljedice ne možemo dokazati
C Što je u logičkom sustavu veći skup epistemičkih pretpostavki, to je manji skup ontoloških pretpostavki
D Uključivanjem varijabli logički sustav može opisati relacije između objekata, ali postaje nepotpun

3. Logičko programiranje i ekspertni sustavi (2 pitanja)

9 (T) Semantika operatora negacije u Prologu (operator `not`) temelji se na pretpostavci zatvorenog svijeta. **Što ta pretpostavka znači?**

A Sve što ne slijedi iz baze znanja je lažno
B Baza sadržava isključivo temeljne atome
C U bazu se ne mogu dodavati nova pravila
D Pravilo *modus ponens* je potpuno

10 (R) Baza znanja ekspertnog sustava sadrži sljedeća pravila:

(1) AKO $(A = a_2) \land (D = d_2)$ ONDA $C = c_1$
(2) AKO $(F = f_3) \lor (B = b_3)$ ONDA $C = c_2$
(3) AKO $(E = e_1) \lor (B = b_1)$ ONDA $(A = a_1) \land (D = d_2)$
(4) AKO $F = f_1$ ONDA $D = d_2$
(5) AKO $F = f_2$ ONDA $E = e_2$
(6) AKO $(B = b_3) \lor (D = d_1)$ ONDA $(E = e_1) \land (A = a_2)$

Sustav koristimo za izvođenje vrijednosti varijable C ulančavanjem unazad. Prednost imaju pravila s manjim rednim brojem. Pravila koja su jednom palila više ne mogu paliti. Jednom izvedeni međuciljevi brišu se sa stoga, neovisno o njihovoj poziciji na stogu. Na moguće upite od strane sustava, korisnik odgovara sa $B = b_3$ i $F = f_1$. **Što radi ekspertni sustav pri izvođenju vrijednosti varijable C?**

A Izvodi $E = e_1$ te kasnije $E = e_2$
B Odbacuje pravilo 5 te kasnije pali pravilo 6
C Pali pet pravila i izvodi $C = c_1$
D Odbacuje pravilo 2 te kasnije pali pravilo 5

4. Modeliranje neizvjesnosti (2 pitanja)

11 (P) Razmotrimo jezičnu varijablu *starost kanarinca*, definiranu s izrazima *mlad* i *star*. Značenje tih izraza modeliramo neirazitim skupovima M odnosno S, definiranima nad univerzalnim skupom $\mathbb{R}^+$, koji odgovara godinama. Funkcije pripadnosti μ_M i μ_S definiramo kao po dijelovima linearne funkcije. Funkcija $\mu_M(x)$ ima vrijednost 1 za $0 \leq x \leq 5$, vrijednost 0 za $x \geq 9$, te linearno pada za $5 < x < 9$. Funkcija $\mu_S(x)$ ima vrijednost 0 za $0 \leq x \leq 6$, vrijednost 1 za $x \geq 12$, te linearno raste za $6 < x < 12$. Uporabom Zadehovih operatora definiramo dva neizrazita skupa: skup X_1 sa značenjem *mlad ili star kanarinac* te skup X_2 sa značenjem *mlad ili ne mlad kanarinac*. **Za koje se sve elemente $x \in \mathbb{R}^+$ pripadnost ovim dvama neizrazitim skupovima razlikuje?**

A $7 \leq x \leq 12$ B $9 \leq x \leq 12$ C $5 \leq x \leq 6$ D $7 \leq x \leq 9$

12 (T) Bayesovo pravilo čini temelj vjerojatnosnog modeliranja neizvjesnog znanja. **Koju vjerojatnost modelira Bayesovo pravilo, i kako?**

A Vjerojatnost hipoteze prije predočavanja dokaza na temelju (1) vjerojatnosti hipoteze uz predočen dokaz i (2) združene vjerojatnosti dokaza i hipoteze

B Združenu vjerojatnost hipoteze i dokaza na temelju (1) uvjetne vjerojatnosti dokaza u predočenu hipotezu i (2) vjerojatnosti dokaza neovisno o hipotezi

C Uvjetnu vjerojatnost dokaza uz predočenu hipotezu na temelju (1) vjerojatnosti hipoteze prije predočavanja dokaza i (2) vjerojatnosti dokaza neovisno o hipotezi

D Uvjetnu vjerojatnost hipoteze uz predočen dokaz na temelju (1) uvjetne vjerojatnost dokaza uz predočenu hipotezu i (2) vjerojatnosti hipoteze prije predočavanja dokaza

5. Strojno učenje, umjetne neuronske mreže i podržano učenje (5 pitanja)

13 (P) Radimo svoju implementaciju algoritma ID3. Kako bismo spriječili da se model prenauči, implementirali smo i podrezivanje stabla na dubini k. Nažalost, kod implementacije funkcije informacijske dobiti (IG) potkrala nam se mala pogreška: zaboravili smo negirati vrijednost pri izračunu entropije $E(D)$ skupa primjera D. Dakle, umjesto da izračunava $E(D)$, naša implementacija izračunava $-E(D)$. Neka je M_1^k stablo odluke koje dobivamo učenjem takvim pogrešno implementiranim algoritmom ID3, podrezano na neku konačnu dubinu k. Neka je M_2^k stablo koje bismo dobili da smo algoritam ID3 implementirali ispravno i naučeno stablo podrezali na neku konačnu dubinu k. Ako $k = \infty$, onda to znači da stablo ne podrezujemo. Neka je $E_u(M)$ pogreška učenja modela M, a $E_p(M)$ pogreška modela M na skupu za provjeru. **Što od sljedećeg možemo očekivati da vrijedi?**

A $E_p(M_2^k) < E_u(M_2^k)$ B $E_p(M_1^k) > E_p(M_2^k)$ C $E_p(M_1^\infty) = E_p(M_2^\infty)$ D $E_p(M_2^\infty) < E_u(M_2^\infty)$

14 (R) Skup primjera za učenje $\{(x_2, x_1, y)\}$ je $\big\{(1,1,-1),(2,4,1),(1,2,-1),(3,3,1),(2,1,-1),(4,2,1)\big\}$. Učenje se provodi uporabom perceptrona TLU s izlaznim vrijednostima -1 i 1 te stopom učenja $\eta = 1$. Početne vrijednosti težinskih faktora su $(w_2, w_1, w_0) = (1.3, -1.2, -10)$. Provedite postupak učenja Rosenblattovim algoritmom. **Koliko se puta tijekom učenja provode korekcije težina te koje su njihove konačne vrijednosti?**

A 4 puta, $(1.3, -2.5, 12)$ B 2 puta, $(3.3, 2.8, -10)$ C Postupak ne konvergira D 4 puta, $(5.5, -1.5, 10)$

15 (R) Treniramo naivan Bayesov klasifikator za *"Skupo ljetovanje na Jadranu"*. Skup za učenje je sljedeći:

i	Mjesto	Otok	Smještaj	Prijevoz	y	i	Mjesto	Otok	Smještaj	Prijevoz	y
1	Kvarner	da	privatni	auto	1	5	Kvarner	ne	kamp	bus	0
2	Dalmacija	da	hotel	avion	1	6	Dalmacija	ne	privatni	avion	0
3	Istra	da	kamp	auto	0	7	Istra	ne	kamp	bus	1
4	Dalmacija	da	hotel	auto	1						

Procjene radimo Laplaceovim procjeniteljem "dodaj jedan". Klasificiramo primjer $\mathbf{x} = (\text{Dalmacija}, \text{ne}, \text{kamp}, \text{bus})$. **Koliko iznosi aposteriorna vjerojatnost $P(y = 1|\mathbf{x})$?**

A 0.685 B 0.237 C 0.318 D 0.706

16 (T) Algoritam propagacije pogreške unazad (engl. *backpropagation algorithm*) rješava problem dodjele odgovornosti pojedinih neurona mreže. Preciznije, algoritam definira kako izračunati pogrešku $\delta_i^{(k)}$ neurona i u sloju k, gdje je k bilo koji skriveni sloj mreže. **O čemu ovisi pogreška $\delta_i^{(k)}$?**

A O izlazima svih neurona u slojevima $k-1$ (sloj bliže ulazu) čiji su izlazi povezani s ulazom neurona i

B O pogreškama svih neurona u sloju $k+1$ (sloj bliže izlazu) čiji su ulazi povezani s izlazom neurona i

C O pogreškama svih neurona u sloju k čiji su izlazi izravno ili neizravno povezani s neuronima izlaznog sloja

D O razlici ostvarnog i ciljanog izlaza, $t_j - o_j$, za sve neurone j u skrivenom sloju $k-1$ (sloj bliže ulazu)

17 (P) Rešetkasti svijet sastoji se od četiri ćelije, označene brojevima 1 do 4 i poredane vodoravno slijeva nadesno. Ćelija 4 je terminalna i agentu donosi 1 bod; nema drugih bodova. Svijet je okružen zidovima. Agent može poduzeti akcije *lijevo* i *desno*. Ako bi ga akcija dovela na zid, ostaje u ćeliji u kojoj je bio. Agent uvijek kreće iz ćelije 1. Provodimo postupak Q-učenja. Početni iznosi Q-funkcije su 0. Parametri su $\alpha = 0.5$ i $\gamma = 1$. Agent najprije igra tri epizode u kojima uvijek bira akciju *desno* i uči. Nakon toga igra još 10 epizoda u kojima u svakoj ćeliji pohlepno odabire potez koji mu se čini optimalan i također uči. **Nakon provedenih svih 13 epizoda, koja je očekivana vrijednost $q(3, desno)$?**

A Veća od 0.9995 B Manja od 0.75 C Između 0.75 i 0.9995 D Nije moguće odgovoriti

6. Prirodom inspirirani optimizacijski algoritmi (3 pitanja)

18 (P) Ako kod algoritma Ant System postavimo parametre $\alpha = 0$ i $\beta = 1$, **što će biti posljedica?**

A Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo heurističkoj informaciji

B U algoritmu se neće događati isparavanje feromonskih tragova

C Vjerojatnost odabira nekog brida bit će linearno proporcionalna isključivo količini feromonskih tragova

D Vjerojatnost odabira nekog brida neće ovisiti o feromonskim tragovima

19 (T) Genetički algoritmi oponašaju proces biološke evolucije te implementiraju operatore selekcije, križanja i mutacije. Neka je P populacija kromosoma te neka je $\mathcal{P}$ skup svih populacija. Neka operatori selekcije, križanja i mutacije odgovaraju funkcijama s, k, odnosno m. **Kako možemo formalno opisati preslikavanja koja obavljaju te funkcije?**

A $s : \mathcal{P} \to P \times P$, $k : P \times P \to P \times P$, $m : P \to P$

B $s : P \to \mathcal{P}$, $k : P \times P \to P$, $m : P \times P \to \mathcal{P}$

C $s : \mathcal{P} \to P$, $k : P \times P \to P$, $m : P \to P \times P$

D $s : \mathcal{P} \to P \times P \times P$, $k : P \times P \to \mathcal{P}$, $m : P \times P \to P$

20 (R) Generacijskim genetskim algoritmom tražimo maksimum funkcije $f(x, y) = 13 - (x-2)^2 - (y-3)^2$. Kao reprezentaciju rješenja koristimo 6-bitovni kromosom, pri čemu se prva tri bita koriste za kodiranje vrijednosti varijable x, a preostala tri bita za kodiranje vrijednosti varijable y. Domena nad kojom se pretražuju vrijednosti od x je $[0, 7]$ te od y je $[-1, 6]$. Populacija se sastoji od četiri jedinke: J1=000110, J2=011001, J3=100111, J4=001110. Pretpostavite da se roditelji biraju proporcionalnom selekcijom te da su u jednom koraku kao roditelji izvučena dva rješenja koja imaju najmanju vjerojatnost odabira. Provedite nad njima postupak križanja s jednom točkom prijeloma (točka prijeloma je nakon prva dva bita); pretpostavite da u ovom koraku operator mutacije svaki puta djeluje na posljednja dva bita kromosoma. **Odredite iznos funkcije f u rješenju koje odgovara djetetu koje će biti poslano u sljedeću generaciju.** (Ako ih operatori križanja i mutacije generiraju više, u novu generaciju treba proslijediti najbolje.)

A 4 B 13 C 11 D 0

Grupa	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	19	20
A	A	D	A	C	A	A	B	2	A	D	B	B	C	C	B	D	A	C	C	B	D
B	C	B	C	C	D	A	2	C	B	B	C	D	B	A	C	A	D	A	D	B	D
C	A	C	D	B	2	D	C	C	B	B	C	B	A	B	A	B	A	D	C	C	C
D	B	D	A	D	2	B	C	B	D	B	D	B	A	A	C	B	D	B	A	C	B
E	D	A	B	A	B	A	2	D	B	D	D	D	B	B	B	D	C	B	D	C	C
F	C	B	C	D	A	2	B	D	C	A	B	B	A	B	A	B	B	B	B	C	D
G	C	C	B	D	B	2	C	C	B	B	D	D	D	A	D	C	B	B	B	C	A
H	D	A	B	B	A	2	A	C	A	A	B	A	D	B	B	C	B	A	A	A	B